Machine Learning - Prevenção de Fraudes

Conjunto de dados com mais de 80.000 registros
Analise exploratória de variáveis categórias e numéricas
Analise e tratamento de valores missing (nulos)
Analise estatística de variáveis
Tratamento de Dados

Engenharia de Atributos

Gráficos
Outliers
Normalização e Padronização de Dados
Balanceamento da variável ALVO (TARGET)

OneHotEncoding
Criação, treino e teste dos modelos preditivos com 3 algoritmos diferentes (Random Forest, Suport Vector Machine e KNN
GridSearch para ajustes de hiperparametros automáticos e treino de mais de 1.000 modelos
Analise dos pesos das melhores variáveis

Importante Pacotes e Carregando o Dataset

In [1]:
```
import warnings
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import time
import numpy as np

from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC
from sklearn.neighbors import KNeighborsClassifier

from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from imblearn import under_sampling, over_sampling
from imblearn.over_sampling import SMOTE
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import r2_score
warnings.filterwarnings("ignore")
pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', None)
pd.options.display.float_format = '{:.2f}'.format
```

In [2]:
```
#Importação do arquivo de dados

#df_original=pd.read_csv("dados_coletados_20k.csv")
#df_original=pd.read_csv("dados_coletados_80k.csv")
```

```
df_original = pd.read_csv("dados_coletados10k.csv")
```

Analise Exploratória - Visão Geral

Aqui o objetivo desta analise é ter uma visão geral do conjunto de dados, compreendendo seu tamanho, variaveis, tipo de dados e período dos dados coletados.

In [3]:
```
#Tamanho do conjunto de dados. xx.xxx linhas e xx variáveis
df_original.shape
```

Out[3]:
```
(9517, 24)
```

In [4]:
```
#Visão geral do conjunto de dados
df_original.head()
```

Out[4]:

	Contrato	Idade	Sexo	Valor_Renda	UF_Cliente	Perc_Juros	Prazo_Emprestimo	Data_Contr
0	322068935715	43	M	5800.00	SP	23.00	200	2022
1	322068936715	22	M	2000.00	MG	20.00	100	2022
2	322068938715	35	M	4000.00	BA	18.00	100	2022
3	322068939715	20	M	1800.00	MG	20.00	100	2022
4	322068940715	53	M	2800.00	MG	20.00	100	2022

In [5]:
```
#Avaliar o período dos dados coletados
inicio = pd.to_datetime(df_original['Data_Contratacao']).dt.date.min()
fim = pd.to_datetime(df_original['Data_Contratacao']).dt.date.max()
print('Período dos dados - De:', inicio, 'Até:',fim)
```

```
Período dos dados - De: 2022-07-04 Até: 2022-12-20
```

In [6]:
```
# Verificando se há valores nulos (dados missing)
df_original.isnull().sum()
```

Out[6]:
```
Contrato                          0
Idade                             0
Sexo                              0
Valor_Renda                       0
UF_Cliente                        0
Perc_Juros                        0
Prazo_Emprestimo                  0
Data_Contratacao                  0
Prazo_Restante                    0
VL_Emprestimo                     0
VL_Emprestimo_ComJuros            0
QT_Total_Parcelas_Pagas           0
QT_Total_Parcelas_Pagas_EmDia     0
QT_Total_Parcelas_Pagas_EmAtraso  0
Qt_Renegociacao                   0
Estado_Civil                      0
Escolaridade                   7105
Possui_Patrimonio                 0
VL_Patrimonio                     0
QT_Parcelas_Atraso                0
QT_Dias_Atraso                 3594
Saldo_Devedor                     0
Total_Pago                        0
Possivel_Fraude                   0
dtype: int64
```

In [7]:
```
#Informações básicas sobre tipos de variáveis
df_original.info(verbose=True)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9517 entries, 0 to 9516
Data columns (total 24 columns):
 #   Column                          Non-Null Count  Dtype  
---  ------                          --------------  -----  
 0   Contrato                        9517 non-null   int64  
 1   Idade                           9517 non-null   int64  
 2   Sexo                            9517 non-null   object 
 3   Valor_Renda                     9517 non-null   float64
 4   UF_Cliente                      9517 non-null   object 
 5   Perc_Juros                      9517 non-null   float64
 6   Prazo_Emprestimo                9517 non-null   int64  
 7   Data_Contratacao                9517 non-null   object 
 8   Prazo_Restante                  9517 non-null   int64  
 9   VL_Emprestimo                   9517 non-null   float64
 10  VL_Emprestimo_ComJuros          9517 non-null   float64
 11  QT_Total_Parcelas_Pagas         9517 non-null   int64  
 12  QT_Total_Parcelas_Pagas_EmDia   9517 non-null   int64  
 13  QT_Total_Parcelas_Pagas_EmAtraso  9517 non-null   int64  
 14  Qt_Renegociacao                 9517 non-null   int64  
 15  Estado_Civil                    9517 non-null   object 
 16  Escolaridade                    2412 non-null   object 
 17  Possui_Patrimonio               9517 non-null   object 
 18  VL_Patrimonio                   9517 non-null   float64
 19  QT_Parcelas_Atraso              9517 non-null   int64  
 20  QT_Dias_Atraso                  5923 non-null   float64
 21  Saldo_Devedor                   9517 non-null   float64
 22  Total_Pago                      9517 non-null   float64
 23  Possivel_Fraude                 9517 non-null   object 
dtypes: float64(8), int64(9), object(7)
memory usage: 1.7+ MB
```

In [9]:
```
# Total de valores únicos de cada variável
# A variável CONTRATO é um valor único para cada registro, pois refere-se ao Contra
valores_unicos = []
```

```
for i in df_original.columns[0:24].tolist():
    print(i, ':', len(df_original[i].astype(str).value_counts()))
    valores_unicos.append(len(df_original[i].astype(str).value_counts()))
```

```
Contrato : 9517
Idade : 74
Sexo : 2
Valor_Renda : 855
UF_Cliente : 27
Perc_Juros : 21
Prazo_Emprestimo : 36
Data_Contratacao : 110
Prazo_Restante : 79
VL_Emprestimo : 61
VL_Emprestimo_ComJuros : 61
QT_Total_Parcelas_Pagas : 24
QT_Total_Parcelas_Pagas_EmDia : 24
QT_Total_Parcelas_Pagas_EmAtraso : 15
Qt_Renegociacao : 10
Estado_Civil : 6
Escolaridade : 6
Possui_Patrimonio : 2
VL_Patrimonio : 3
QT_Parcelas_Atraso : 16
QT_Dias_Atraso : 16
Saldo_Devedor : 7654
Total_Pago : 7022
Possivel_Fraude : 2
```

In [10]:
```
# Visualizando algumas medidas estatisticas.
df_original.describe()
```

Out[10]:

	Contrato	Idade	Valor_Renda	Perc_Juros	Prazo_Emprestimo	Prazo_Restante	VL_E
count	9517.00	9517.00	9517.00	9517.00	9517.00	9517.00	
mean	322078158460.93	38.74	8325.40	19.65	107.43	104.58	
std	5434160.86	12.67	121862.06	3.82	62.49	68.57	
min	322068935715.00	6.00	450.00	7.00	15.00	0.00	
25%	322073331715.00	29.00	2300.00	18.00	60.00	51.00	
50%	322078461715.00	37.00	3400.00	20.00	80.00	80.00	
75%	322082622715.00	46.00	5000.00	22.00	190.00	185.00	
max	322087622715.00	91.00	8000080.00	28.00	240.00	227.00	

In [10]:
```
# Avaliando o maior e menor valor da variavel Valor_Renda
print('Maior Renda:', df_original['Valor_Renda'].max())
print('Menor Renda:', df_original['Valor_Renda'].min())
```

```
Maior Renda: 8000080.0
Menor Renda: 450.0
```

In [11]:
```
# Avaliando o maior e menor valor da variavel QT_Dias_Atraso
print('Maior quantidade de dias atraso: ', df_original['QT_Dias_Atraso'].max())
print('Menor quantidade de dias atraso: ', df_original['QT_Dias_Atraso'].min())
```

```
Maior quantidade de dias atraso:  435.0
Menor quantidade de dias atraso:  11.0
```

In [12]:
```
# Avaliando o maior e menor valor da variavel Prazo_Restante
print('Maior quantidade de dias restante: ', df_original['Prazo_Restante'].max())
print('Menor quantidade de dias restante: ', df_original['Prazo_Restante'].min())
```

```
Maior quantidade de dias restante:  227
Menor quantidade de dias restante:  0
```

In [13]:
```
# Quantidade de dias em atraso
df_original.groupby(['QT_Dias_Atraso']).size()
```

Out[13]:
```
QT_Dias_Atraso
11.00     532
41.00     255
71.00     190
103.00    205
133.00    176
162.00    206
194.00    241
225.00    352
251.00    471
284.00    546
315.00    718
344.00    930
376.00    686
406.00    413
435.00      2
dtype: int64
```

In [14]:
```
# Prazo emprestimo
df_original.groupby(['Prazo_Emprestimo']).size()
```

Out[14]:
```
Prazo_Emprestimo
15        4
18        4
19        5
20      146
25      183
30      272
34        1
35       81
36      306
40      136
42       20
45      205
48      333
50      184
55      185
60      890
65       36
70      134
75      455
80     1421
88        2
90      354
95      135
100     928
120     102
130      21
140     167
150      48
160      33
165       3
170      78
180     129
190     674
200    1661
235      71
240     110
dtype: int64
```

In [15]:
```
# Prazo Restante
df_original.groupby(['Prazo_Restante']).size()
```

Out[15]:

	Prazo_Restante
0	2
3	3
4	2
6	22
7	29
8	31
9	8
10	12
11	32
12	6
13	94
15	10
16	42
17	85
18	27
19	143
20	23
23	164
25	84
27	38
28	52
29	71
30	51
31	71
33	40
34	67
35	168
36	204
37	31
38	55
39	22
40	73
41	37
42	14
43	27
44	126
45	19
46	2
49	145
50	19
51	256
53	150
59	7
60	178
64	421
66	43
68	330
71	270
74	304
75	193
76	99
77	67
78	63
79	86
80	188
82	159
84	48
85	72
87	129
89	420
91	705
100	15
107	43

```
120     24
125     68
129     44
133     25
143    197
149     16
156     39
159     58
175    119
179     27
185    332
193    764
198    337
221     17
225    534
227    519
dtype: int64
```

In [16]:
```
# Sexo
df_original.groupby(['Sexo']).size()
```

Out[16]:
```
Sexo
F    3811
M    5706
dtype: int64
```

In [17]:
```
# UF dos Clientes
df_original.groupby(['UF_Cliente']).size()
```

Out[17]:
```
UF_Cliente
AC       1
AL      79
AM       2
AP       5
BA     883
CE     248
DF      46
ES      49
GO     485
MA     403
MG    1637
MS     238
MT     137
PA     420
PB     154
PE     263
PI     104
PR     693
RJ     335
RN      78
RO      16
RR       4
RS     407
SC     298
SE      45
SP    2468
TO      19
dtype: int64
```

In [18]:
```
# Idade dos clientes
df_original.groupby(['Idade']).size()
```

Out[18]:

Idade	
6	1
17	4
18	6
19	109
20	207
21	193
22	173
23	234
24	251
25	253
26	296
27	277
28	280
29	298
30	284
31	281
32	288
33	273
34	310
35	336
36	280
37	262
38	271
39	270
40	264
41	270
42	243
43	233
44	285
45	229
46	208
47	177
48	167
49	172
50	148
51	143
52	118
53	122
54	124
55	124
56	96
57	76
58	90
59	79
60	99
61	71
62	56
63	49
64	54
65	37
66	65
67	39
68	48
69	33
70	27
71	16
72	19
73	16
74	16
75	7
76	12
77	5
78	5

```
79      3
80      9
81      5
82      3
83      4
84      2
85      5
87      2
88      2
90      2
91      1
dtype: int64
```

In [19]:
```
# Estado civil dos clientes
df_original.groupby(['Estado_Civil']).size()
```

Out[19]:
```
Estado_Civil
CASADO (A)       3027
DIVORCIADO        481
OUTRO             652
SOLTEIRO(A)      5087
UNIÃO ESTAVEL     130
VIÚVO(A)          140
dtype: int64
```

In [20]:
```
# Escolaridade dos clientes
df_original.groupby(['Escolaridade']).size()
```

Out[20]:
```
Escolaridade
Ensino Fundamental                       18
Ensino Médio                            129
Ensino Superior                          74
Nenhum                                 2184
Pós Graduação / Mestrado / Doutorado      7
dtype: int64
```

In [21]:
```
# Patrimonio dos clientes
df_original.groupby(['Possui_Patrimonio']).size()
```

Out[21]:
```
Possui_Patrimonio
N    9452
S      65
dtype: int64
```

In [22]:
```
# Valor do patrimonio dos clientes
df_original.groupby(['VL_Patrimonio']).size()
```

Out[22]:
```
VL_Patrimonio
0.00         9512
1000.00         4
100000.00       1
dtype: int64
```

In [23]:
```
# Variavel TARGET - ALVO
df_original.groupby(['Possivel_Fraude']).size()
```

Out[23]:
```
Possivel_Fraude
Nao    5035
Sim    4482
dtype: int64
```

In [ ]:
```
# Tratando os dados que identificamos que precisam ser ajustados em nossa analise d
```

In [24]:
```
# Ajustando ESTADO_CIVIL
df_original['Estado_Civil'] = df_original['Estado_Civil'].replace(['NENHUM'], 'OUTR
```

```
df_original['Estado_Civil'] = df_original['Estado_Civil'].replace(['UNIÃO ESTAVEL']

df_original.groupby(['Estado_Civil']).size()
```

Out[24]:
```
Estado_Civil
CASADO (A)     3157
DIVORCIADO      481
OUTRO           652
SOLTEIRO(A)    5087
VIÚVO(A)        140
dtype: int64
```

In [25]:
```
# Criando faixa etaria para utilizarmos no modelo preditivo
bins = [0, 21, 30, 40, 50, 60, 100]
labels = ['Até 21 Anos', 'De 22 até 30 Anos', 'De 31 até 40 Anos', 'De 41 até 50 An
df_original['Faixa_Etaria'] = pd.cut(df_original['Idade'], bins=bins, labels=labels
df_original.groupby(['Faixa_Etaria']).size()
```

Out[25]:
```
Faixa_Etaria
Até 21 Anos           520
De 22 até 30 Anos    2346
De 31 até 40 Anos    2835
De 41 até 50 Anos    2132
De 51 até 60         1071
Acima de 60 Anos      613
dtype: int64
```

In [26]:
```
df_original.head()
```

Out[26]:

	Contrato	Idade	Sexo	Valor_Renda	UF_Cliente	Perc_Juros	Prazo_Emprestimo	Data_Contr
0	322068935715	43	M	5800.00	SP	23.00	200	2022
1	322068936715	22	M	2000.00	MG	20.00	100	2022
2	322068938715	35	M	4000.00	BA	18.00	100	2022
3	322068939715	20	M	1800.00	MG	20.00	100	2022
4	322068940715	53	M	2800.00	MG	20.00	100	2022

In [27]:
```
# Criando faixa salarial para utilizarmos no modelo preditivo
bins = [-100, 1000, 2000, 3000, 5000, 10000, 20000, 30000, 9000000000]
labels = ['Até 1k', 'De 1k até 2k', 'De 2k até 3k', 'De 3k até 5k', 'De 5k até 10k'
          'De 20k até 30k', 'Acima de 50k']
df_original['Faixa_Salarial'] = pd.cut(df_original['Valor_Renda'], bins=bins, label
df_original.groupby(['Faixa_Salarial']).size()
```

Out[27]:
```
Faixa_Salarial
Até 1k              19
De 1k até 2k      2012
De 2k até 3k      2522
De 3k até 5k      2646
De 5k até 10k     1574
De 10k até 20k     488
De 20k até 30k     137
Acima de 50k       119
dtype: int64
```

In [28]:
```
# Precisamos tratar os valores nulos dessa variavel antes de fazermos nossa engenha
# Vamos preencher os valores nulos usando a mediana dos dados
df_original['QT_Dias_Atraso'].median()
```

Out[28]:
```
284.0
```

In [29]:
```
# Preenchendo os valores nulo com a mediana
df_original['QT_Dias_Atraso'] = df_original['QT_Dias_Atraso'].fillna((df_original['
```

In [30]:
```
# Criando faixa de dias em atraso da cota para utilizarmos no modelo preditivo
bins = [-100, 30, 60, 90, 180, 240, 360, 500]
labels = ['Até 30 dias', 'De 31 até 60', 'De 61 até 90', 'De 91 até 180', 'De 181 a
df_original['Faixa_Dias_Atraso'] = pd.cut(df_original['QT_Dias_Atraso'], bins=bins,
df_original.groupby(['Faixa_Dias_Atraso']).size()
```

Out[30]:
```
Faixa_Dias_Atraso
Até 30 dias        532
De 31 até 60       255
De 61 até 90       190
De 91 até 180      587
De 181 até 240     593
De 241 até 360    6259
Acima de 360      1101
dtype: int64
```

In [31]:
```
# Criando faixa de prazo de emprestimo para utilizarmos no modelo preditivo
bins = [0, 60, 120, 200, 720]
labels = ['Até 60 Meses', 'De 61 até 120 Meses', 'De 121 até 200 Meses', 'Acima de
df_original['Faixa_Prazo_Emprestimo'] = pd.cut(df_original['Prazo_Emprestimo'], bir
pd.value_counts(df_original.Faixa_Prazo_Emprestimo)
```

Out[31]:
```
De 61 até 120 Meses     3567
Até 60 Meses            2955
De 121 até 200 Meses    2814
Acima de 200 Meses       181
Name: Faixa_Prazo_Emprestimo, dtype: int64
```

In [32]:
```
# Criando faixa de prazo restante do emprestimo para utilizarmos no modelo preditiv
bins = [-1, 60, 120, 200, 500]
labels = ['Até 60 Meses', 'De 61 até 120 Meses', 'De 121 até 200 Meses', 'Acima de
df_original['Faixa_Prazo_Restante'] = pd.cut(df_original['Prazo_Restante'], bins=bi
pd.value_counts(df_original.Faixa_Prazo_Restante)
```

Out[32]:
```
De 61 até 120 Meses     3679
Até 60 Meses            2742
De 121 até 200 Meses    2026
Acima de 200 Meses      1070
Name: Faixa_Prazo_Restante, dtype: int64
```

In [ ]:
```
# Agora após os ajustes vamos visualizar de forma gráfica para avaliarmos melhor
```

In [33]:
```
df_original.Sexo.value_counts().plot(kind='bar', title='Sexo',color = ['#1F77B4', '
```

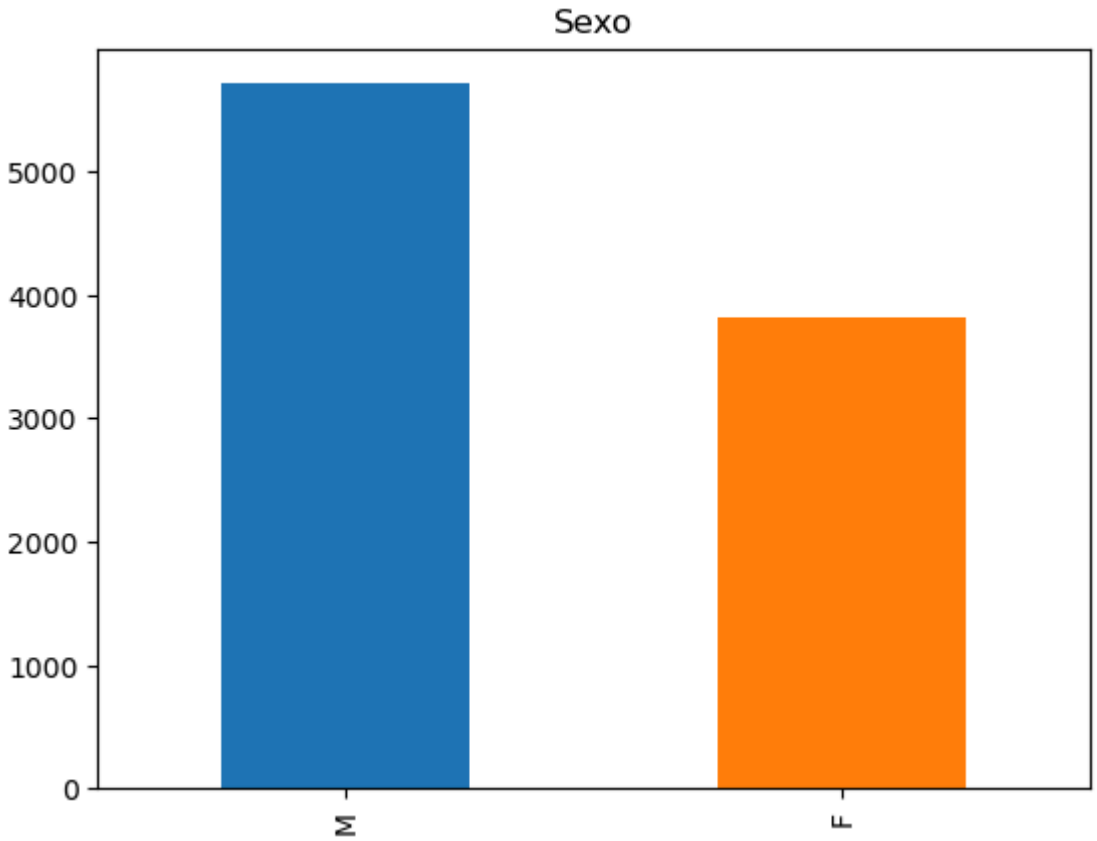

In [34]:
```
df_original.UF_Cliente.value_counts().plot(kind='bar', title='UF Cliente',color = [
```

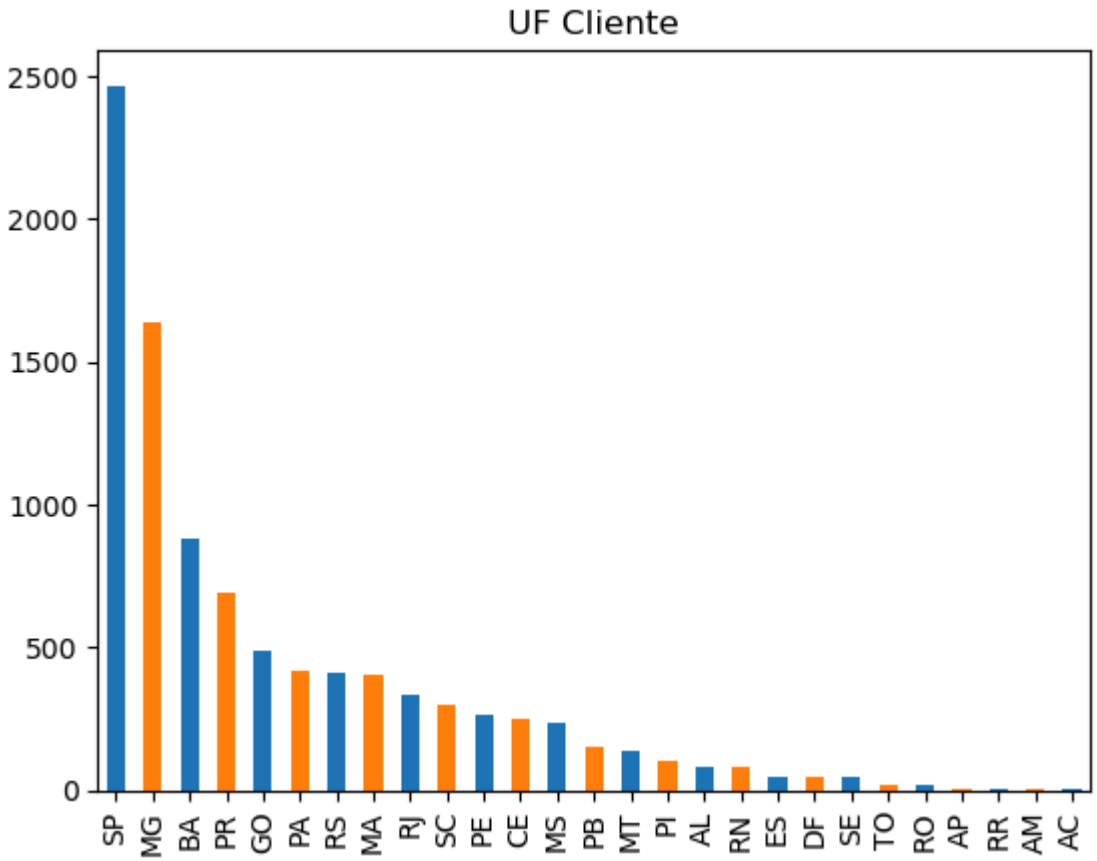

In [35]:
```
df_original.Faixa_Prazo_Emprestimo.value_counts().plot(kind='bar', title='Prazo Emp
```

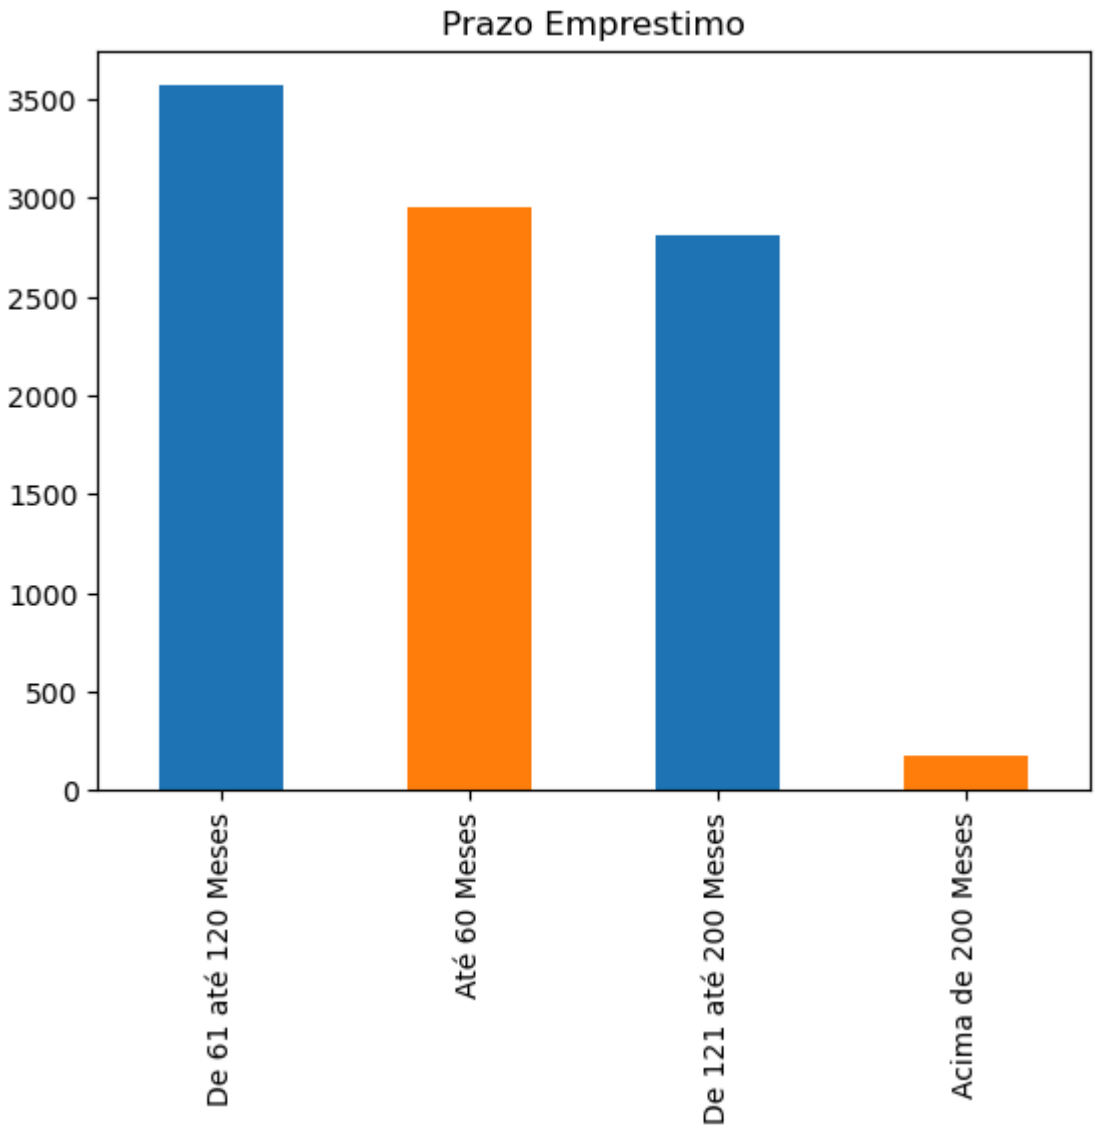

In [36]:
```
df_original.Faixa_Prazo_Restante.value_counts().plot(kind='bar', title='Prazo Resta
```

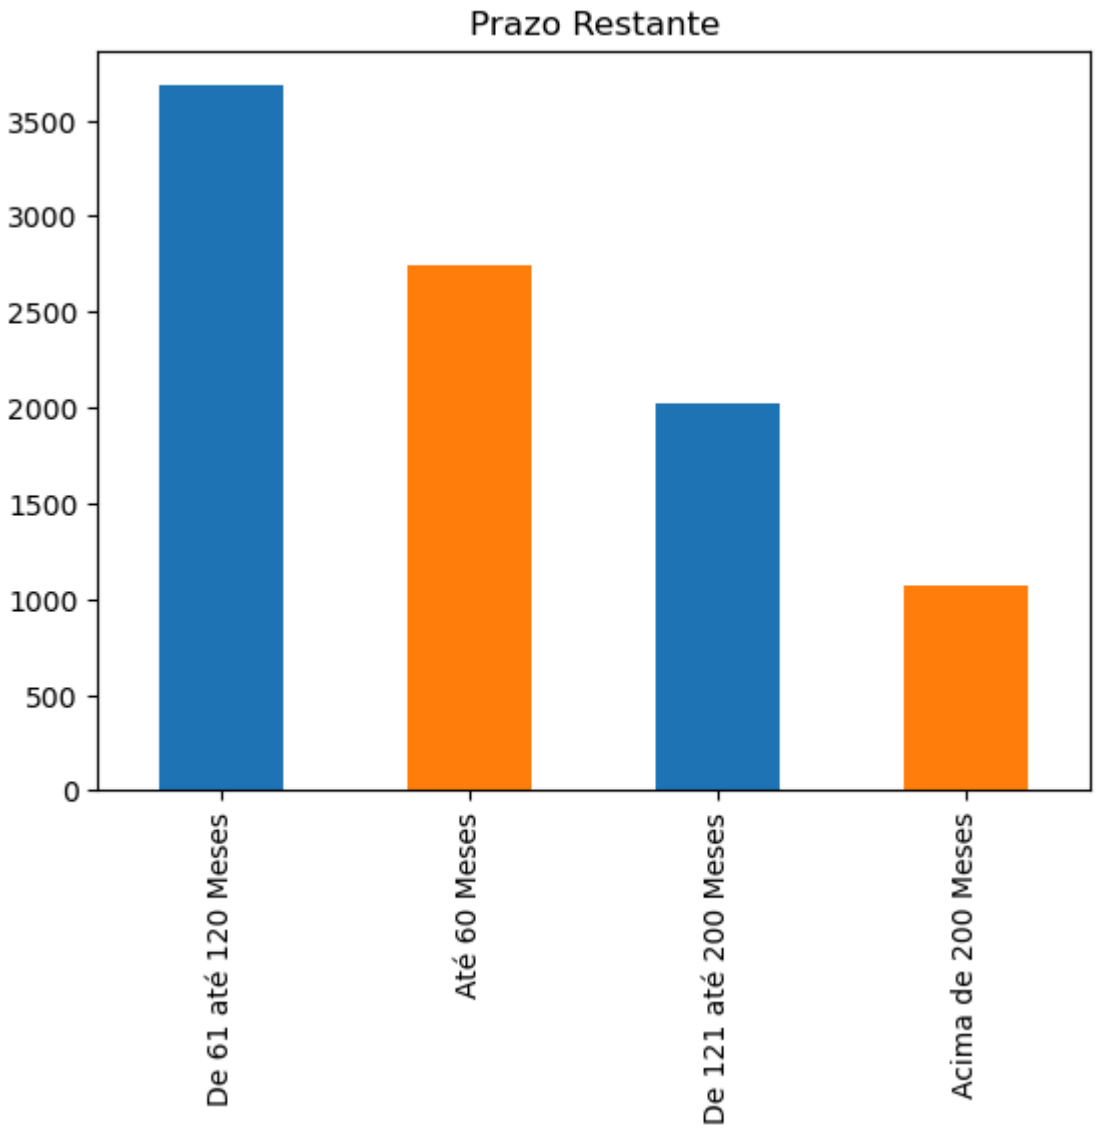

In [37]:
```
df_original.Estado_Civil.value_counts().plot(kind='bar', title='Estado Civil',color
```

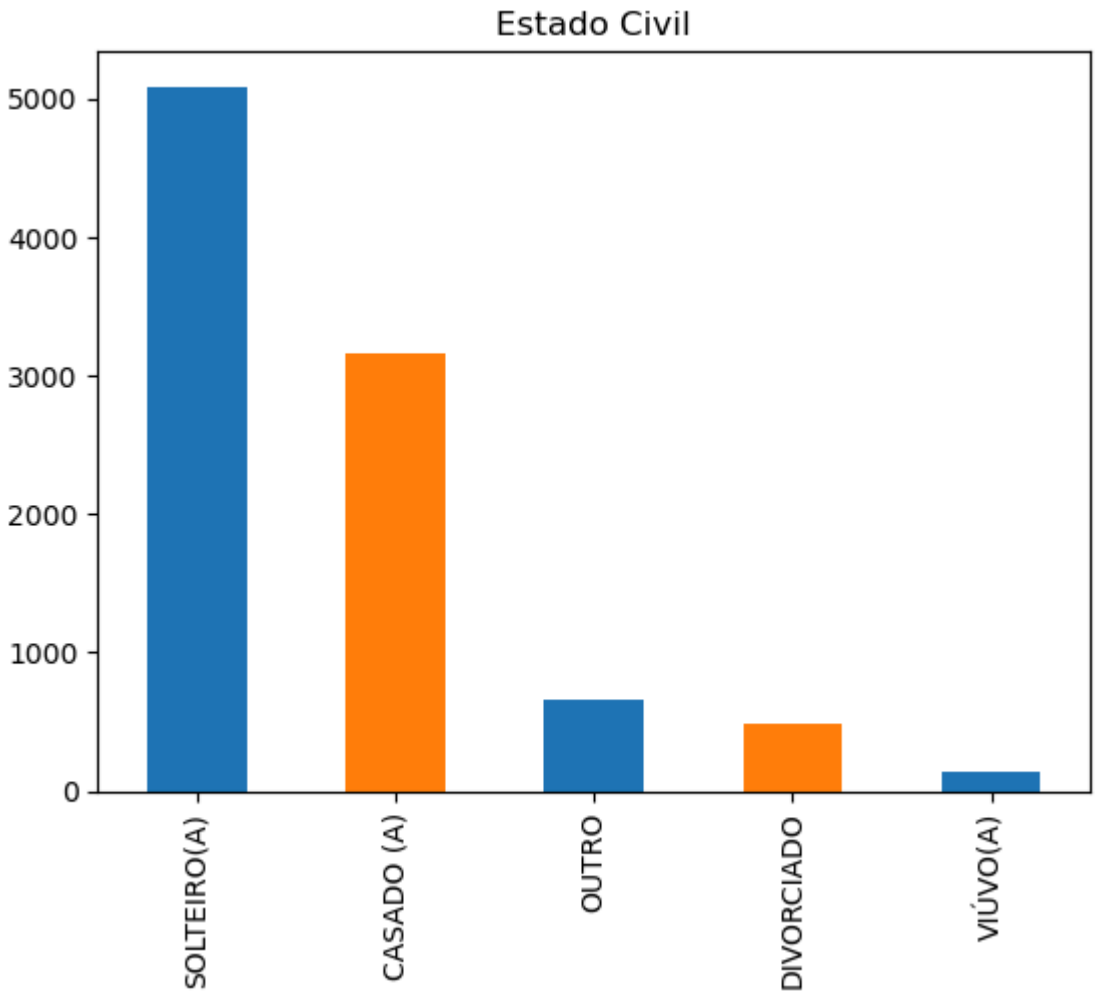

In [38]:
```
df_original.Escolaridade.value_counts().plot(kind='bar', title='Escolaridade',color
```

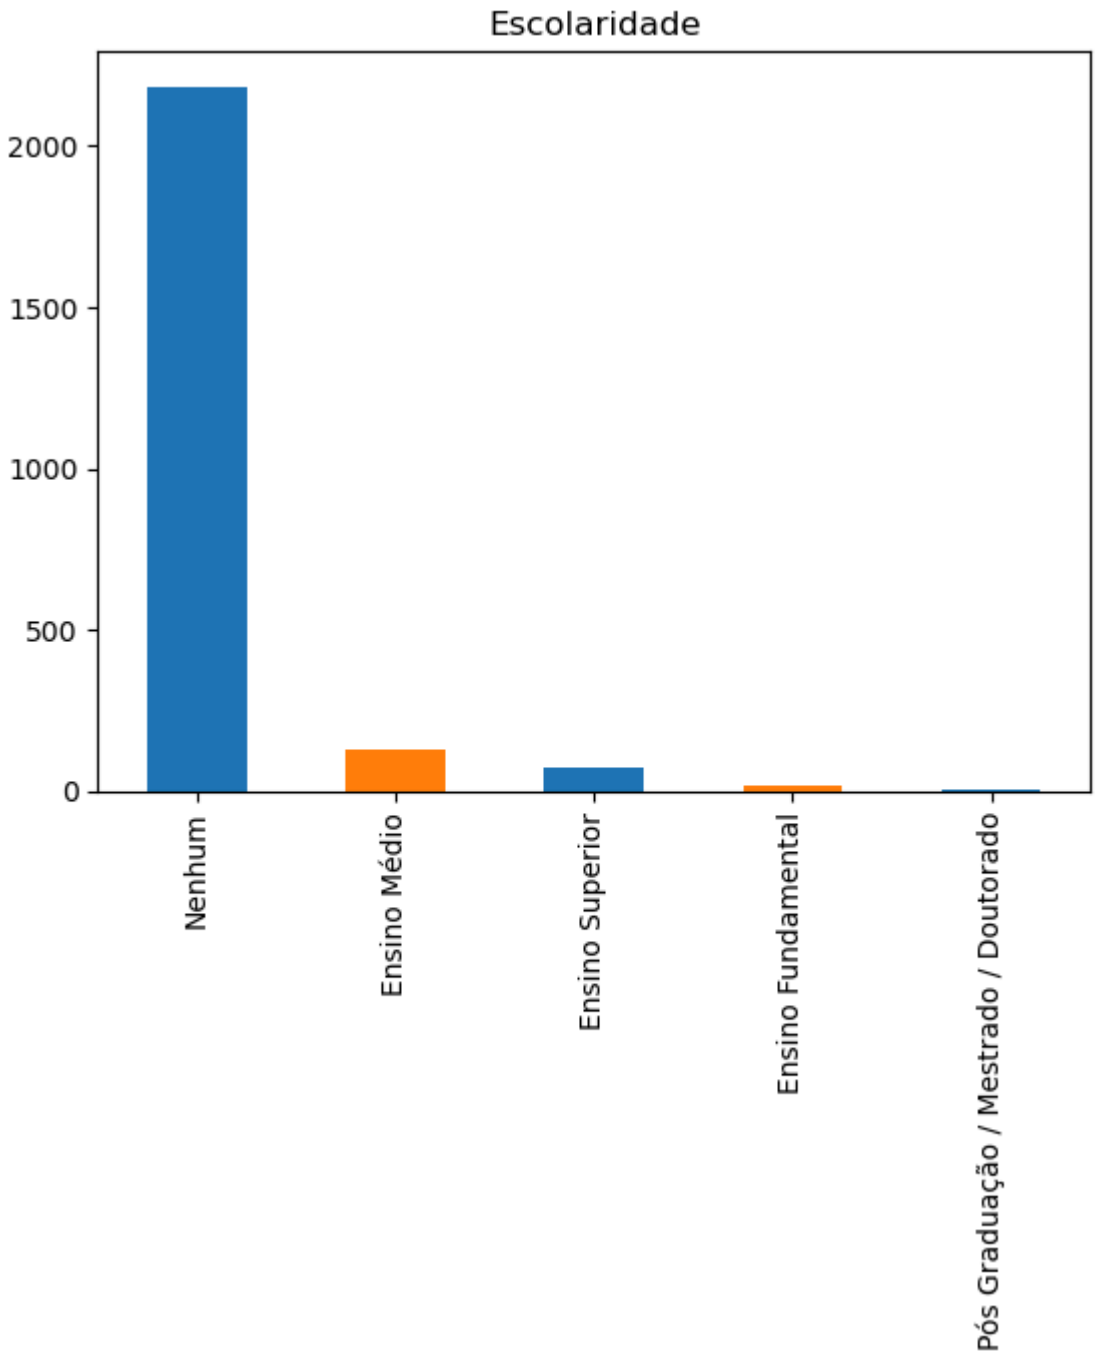

In [39]:
```
df_original.Faixa_Dias_Atraso.value_counts().plot(kind='bar', title='Faixa Dias Atr
```

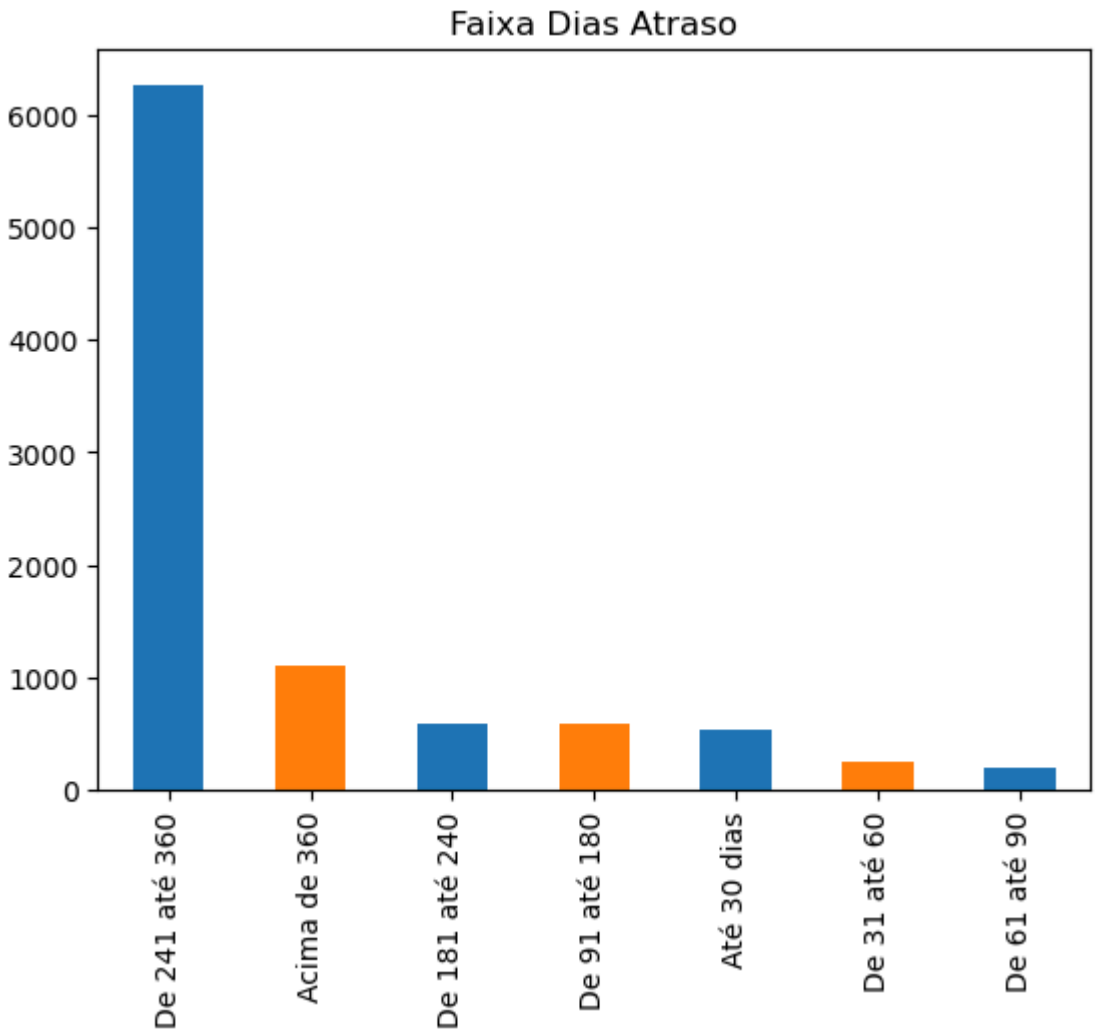

In [40]:
```
df_original.Faixa_Salarial.value_counts().plot(kind='bar', title='Faixa Salarial',c
```

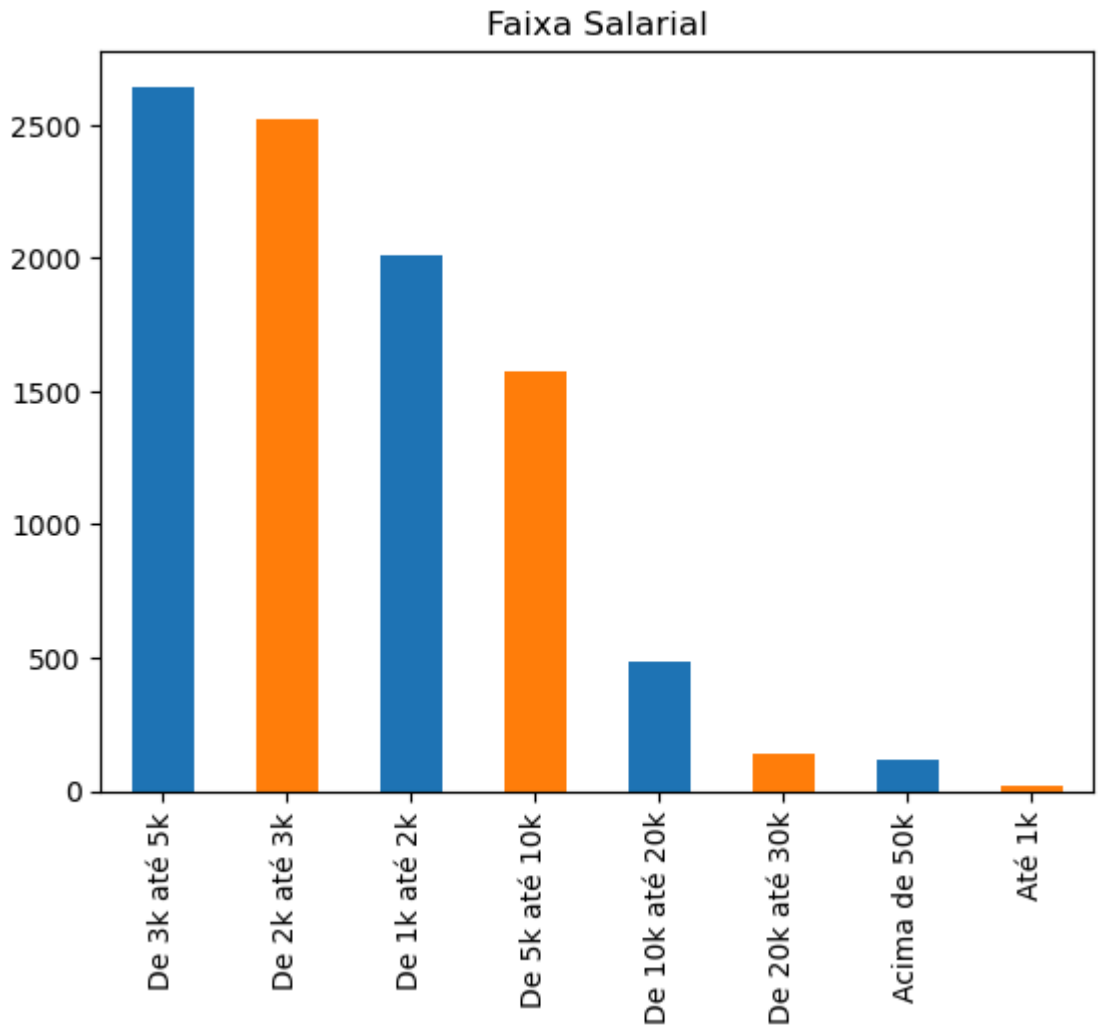

In [41]:
```
df_original.Possui_Patrimonio.value_counts().plot(kind='bar', title='Possui Patrimc
```

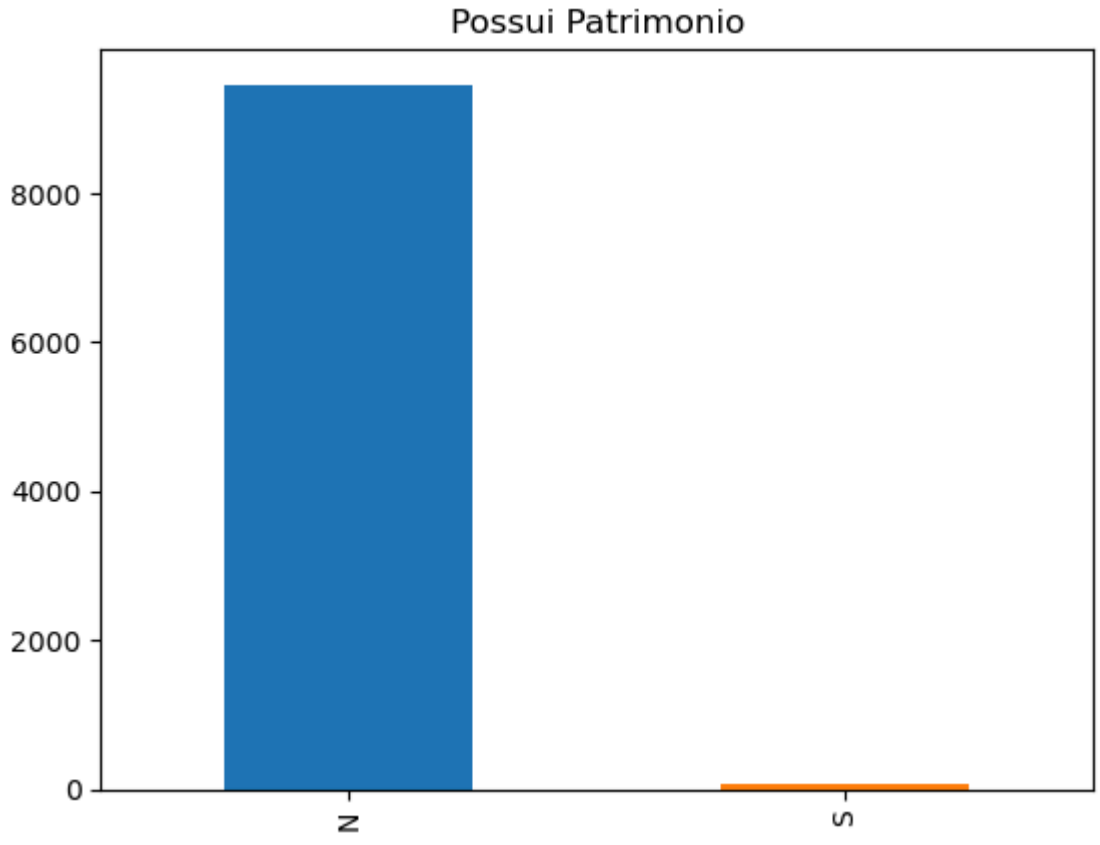

In [42]:
```
df_original.Faixa_Etaria.value_counts().plot(kind='bar', title='Faixa Etaria',color
```

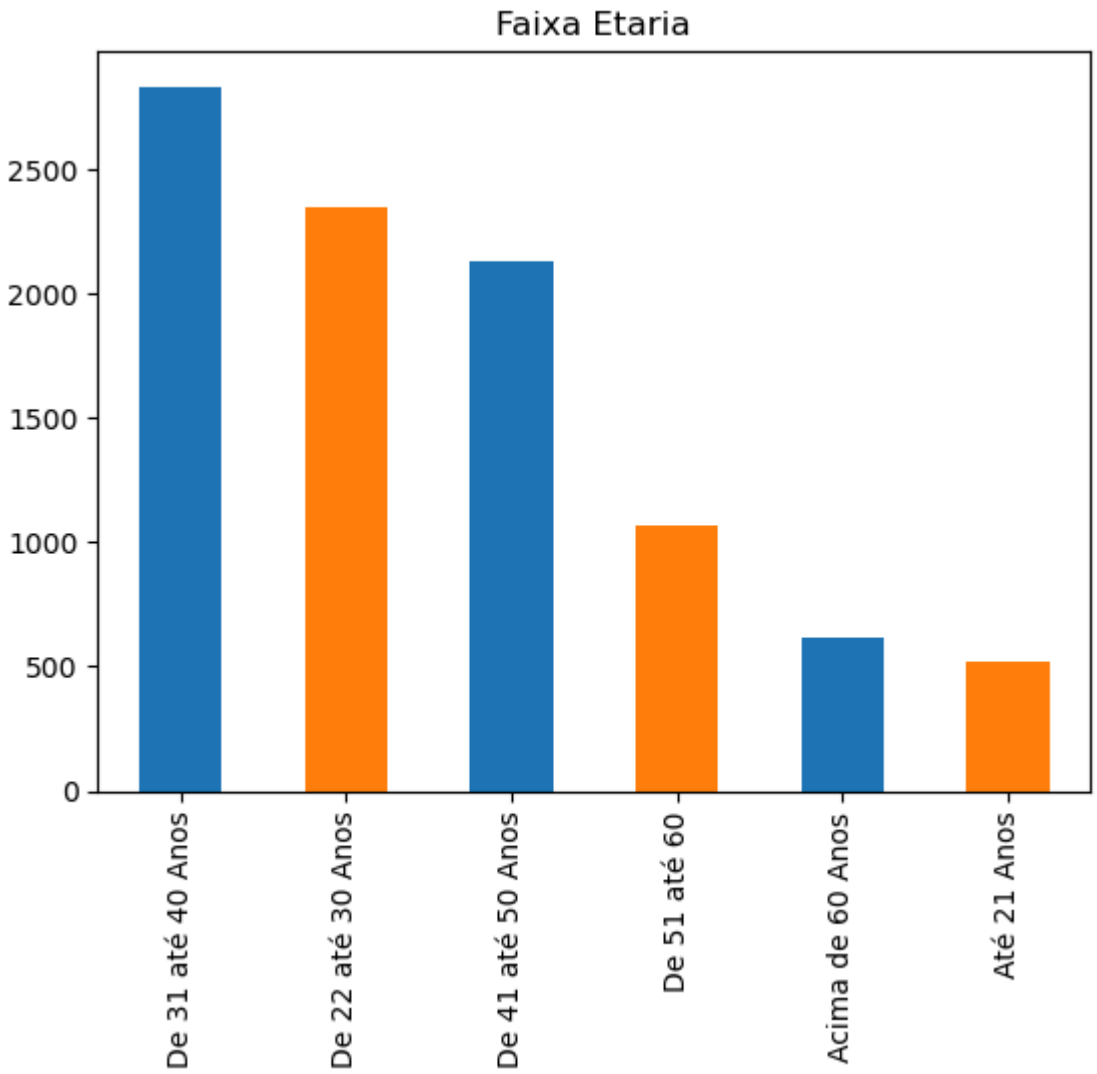

In [43]:
```
#Analisando como a variavel alvo está distribuida.
#Aqui podemos observar que há muito mais cotas como NÃO POSSÍVEL FRAUDE
#dessa forma, precisaremos balancear o dataset mais adiante.
df_original.Possivel_Fraude.value_counts().plot(kind='bar', title='Possíveis Fraude
```

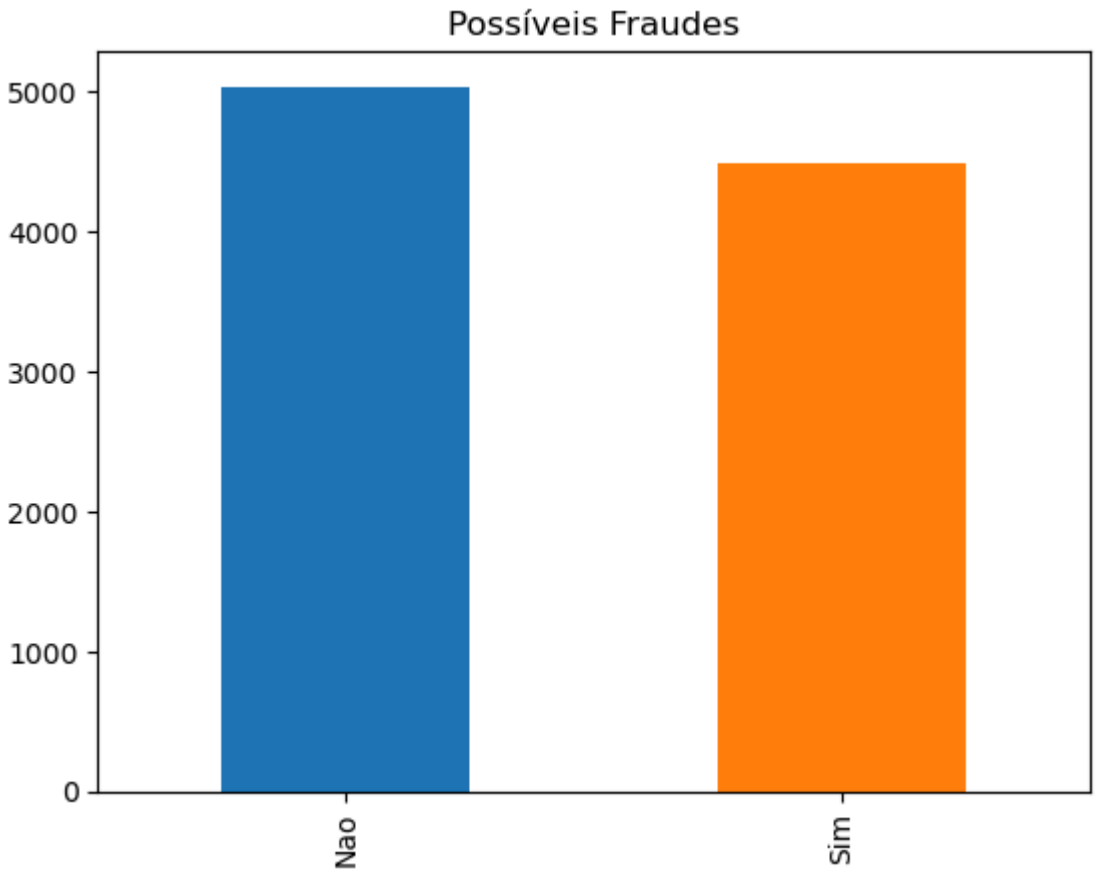

In [44]:
```
# Vamos visualizar novamente como está nosso DataFrame original após a engenharia d
df_original.info(verbose=True)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9517 entries, 0 to 9516
Data columns (total 29 columns):
 #   Column                            Non-Null Count  Dtype
---  ------                            --------------  -----
 0   Contrato                          9517 non-null   int64
 1   Idade                             9517 non-null   int64
 2   Sexo                              9517 non-null   object
 3   Valor_Renda                       9517 non-null   float64
 4   UF_Cliente                        9517 non-null   object
 5   Perc_Juros                        9517 non-null   float64
 6   Prazo_Emprestimo                  9517 non-null   int64
 7   Data_Contratacao                  9517 non-null   object
 8   Prazo_Restante                    9517 non-null   int64
 9   VL_Emprestimo                     9517 non-null   float64
 10  VL_Emprestimo_ComJuros            9517 non-null   float64
 11  QT_Total_Parcelas_Pagas           9517 non-null   int64
 12  QT_Total_Parcelas_Pagas_EmDia     9517 non-null   int64
 13  QT_Total_Parcelas_Pagas_EmAtraso  9517 non-null   int64
 14  Qt_Renegociacao                   9517 non-null   int64
 15  Estado_Civil                      9517 non-null   object
 16  Escolaridade                      2412 non-null   object
 17  Possui_Patrimonio                 9517 non-null   object
 18  VL_Patrimonio                     9517 non-null   float64
 19  QT_Parcelas_Atraso                9517 non-null   int64
 20  QT_Dias_Atraso                    9517 non-null   float64
 21  Saldo_Devedor                     9517 non-null   float64
 22  Total_Pago                        9517 non-null   float64
 23  Possivel_Fraude                   9517 non-null   object
 24  Faixa_Etaria                      9517 non-null   category
 25  Faixa_Salarial                    9517 non-null   category
 26  Faixa_Dias_Atraso                 9517 non-null   category
 27  Faixa_Prazo_Emprestimo            9517 non-null   category
 28  Faixa_Prazo_Restante              9517 non-null   category
dtypes: category(5), float64(8), int64(9), object(7)
memory usage: 1.8+ MB
```

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [45]:
```
# Vamos selecionar as colunas que iremos utilizar e algumas iremos descartar
df_original.columns
```

Out[45]:
```
Index(['Contrato', 'Idade', 'Sexo', 'Valor_Renda', 'UF_Cliente', 'Perc_Juros',
       'Prazo_Emprestimo', 'Data_Contratacao', 'Prazo_Restante',
       'VL_Emprestimo', 'VL_Emprestimo_ComJuros', 'QT_Total_Parcelas_Pagas',
       'QT_Total_Parcelas_Pagas_EmDia', 'QT_Total_Parcelas_Pagas_EmAtraso',
       'Qt_Renegociacao', 'Estado_Civil', 'Escolaridade', 'Possui_Patrimonio',
       'VL_Patrimonio', 'QT_Parcelas_Atraso', 'QT_Dias_Atraso',
       'Saldo_Devedor', 'Total_Pago', 'Possivel_Fraude', 'Faixa_Etaria',
       'Faixa_Salarial', 'Faixa_Dias_Atraso', 'Faixa_Prazo_Emprestimo',
       'Faixa_Prazo_Restante'],
      dtype='object')
```

In [46]:
```
# APÓS ANALISE INICIAL QUE REALIZAMOS ACIMA, ENTENDEMOSO QUE ALGUMAS VARIÁVEIS NÃO

#  Contrato --> Essa variável é a identificação de cada cliente
#  Data_Contratacao, VL_Patrimonio, Possui_Patrimonio, Escolaridade, Idade --> Essa
```

```
#  Valor_Renda, Prazo_Emprestimo, QT_Dias_Atraso, Prazo_Restante --> Essas variávei


# Chamaremos nosso novo conjunto de dados de df_dados

columns = ['Sexo', 'UF_Cliente', 'Perc_Juros',
       'VL_Emprestimo', 'VL_Emprestimo_ComJuros', 'QT_Total_Parcelas_Pagas',
       'QT_Total_Parcelas_Pagas_EmDia', 'QT_Total_Parcelas_Pagas_EmAtraso',
       'Qt_Renegociacao', 'Estado_Civil', 'QT_Parcelas_Atraso', 'Saldo_Devedor',
       'Total_Pago', 'Faixa_Prazo_Restante', 'Faixa_Salarial', 'Faixa_Prazo_Emprest
       'Faixa_Dias_Atraso', 'Possivel_Fraude']

df_dados = pd.DataFrame(df_original, columns=columns)
```

In [47]:
```
df_dados.shape
```

Out[47]:
```
(9517, 19)
```

In [48]:
```
df_dados.info(verbose = True)
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9517 entries, 0 to 9516
Data columns (total 19 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   Sexo                            9517 non-null   object
 1   UF_Cliente                      9517 non-null   object
 2   Perc_Juros                      9517 non-null   float64
 3   VL_Emprestimo                   9517 non-null   float64
 4   VL_Emprestimo_ComJuros          9517 non-null   float64
 5   QT_Total_Parcelas_Pagas         9517 non-null   int64
 6   QT_Total_Parcelas_Pagas_EmDia   9517 non-null   int64
 7   QT_Total_Parcelas_Pagas_EmAtraso  9517 non-null   int64
 8   Qt_Renegociacao                 9517 non-null   int64
 9   Estado_Civil                    9517 non-null   object
 10  QT_Parcelas_Atraso              9517 non-null   int64
 11  Saldo_Devedor                   9517 non-null   float64
 12  Total_Pago                      9517 non-null   float64
 13  Faixa_Prazo_Restante            9517 non-null   category
 14  Faixa_Salarial                  9517 non-null   category
 15  Faixa_Prazo_Emprestimo          9517 non-null   category
 16  Faixa_Etaria                    9517 non-null   category
 17  Faixa_Dias_Atraso               9517 non-null   category
 18  Possivel_Fraude                 9517 non-null   object
dtypes: category(5), float64(5), int64(5), object(4)
memory usage: 1.1+ MB
```

In [49]:
```
# Vamos constatar que realmente não há valores nulos
df_dados.isnull().sum()
```

Out[49]:
```
Sexo                              0
UF_Cliente                        0
Perc_Juros                        0
VL_Emprestimo                     0
VL_Emprestimo_ComJuros            0
QT_Total_Parcelas_Pagas           0
QT_Total_Parcelas_Pagas_EmDia     0
QT_Total_Parcelas_Pagas_EmAtraso  0
Qt_Renegociacao                   0
Estado_Civil                      0
QT_Parcelas_Atraso                0
Saldo_Devedor                     0
Total_Pago                        0
Faixa_Prazo_Restante              0
Faixa_Salarial                    0
Faixa_Prazo_Emprestimo            0
Faixa_Etaria                      0
Faixa_Dias_Atraso                 0
Possivel_Fraude                   0
dtype: int64
```

Analise Exploratória em Variáveis Categóricas

Nesta analise temos 2 objetivos:

1 - Conhecer como a variável alvo (POSSIVEL_FRAUDE) está relacionada com as outras variáveis.

2 - Iremos avaliar as variáveis categóricas para conhecimento dos dados e descartar variáveis que não fazem sentido.

In [50]:
```
# Apenas para ajustar o tamanho dos gráficos
plt.rcParams["figure.figsize"] = [10.00, 4.00]
plt.rcParams["figure.autolayout"] = True
```

In [51]:
```
#Podemos constatar na analise que não há discrepancias nestas variaveis

sns.countplot(data = df_dados, x = "UF_Cliente", hue = "Possivel_Fraude")
plt.show()
```

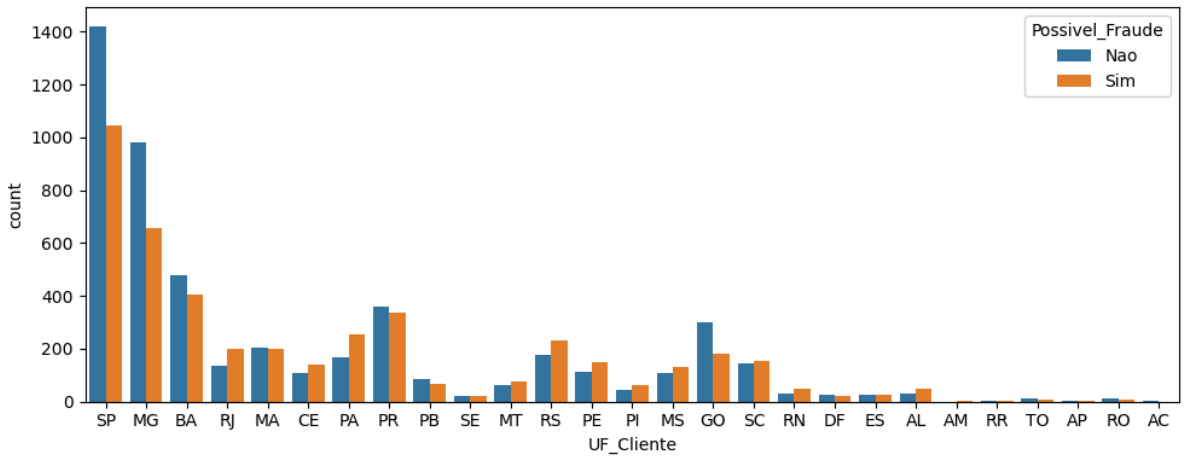

In [52]:
```
#Podemos constatar na analise que não há discrepancias nestas variaveis

sns.countplot(data = df_dados, x = "Sexo", hue = "Possivel_Fraude")
plt.show()
```

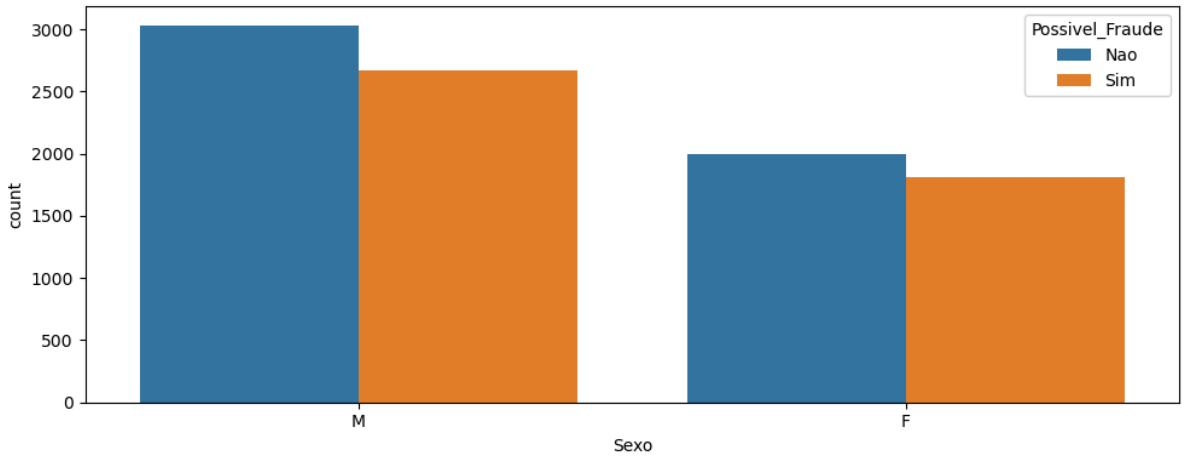

In [53]:
```
#Podemos constatar na analise que não há discrepancias nestas variaveis
sns.countplot(data = df_dados, x = "Faixa_Etaria", hue = "Possivel_Fraude")
plt.show()
```

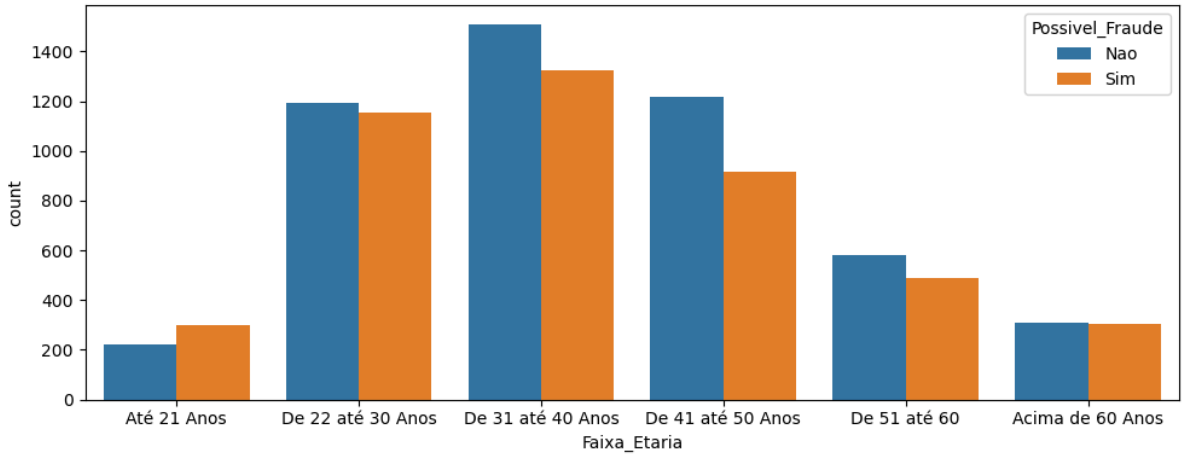

In [54]:
```
#Podemos constatar na analise que não há discrepancias nestas variaveis
sns.countplot(data = df_dados, x = "Faixa_Salarial", hue = "Possivel_Fraude")
plt.show()
```

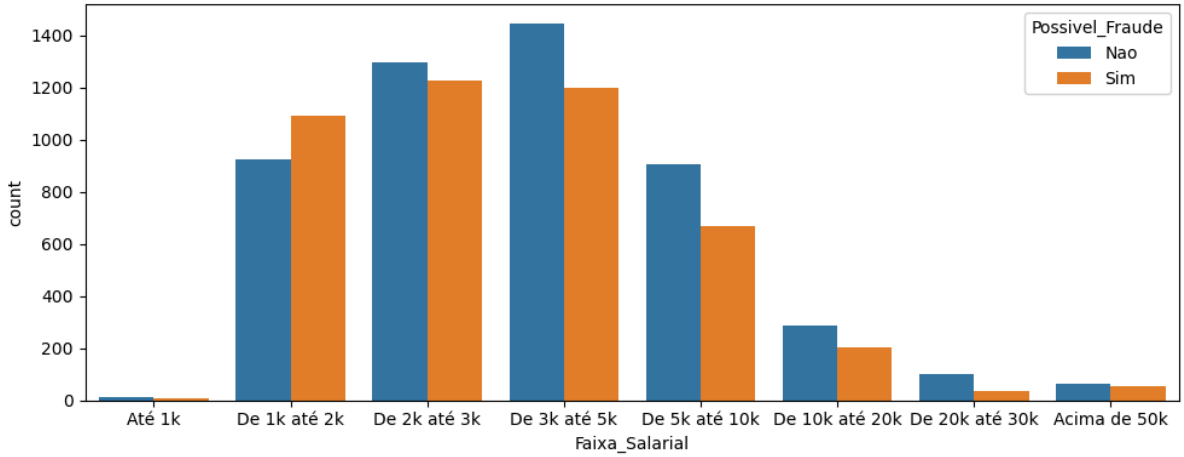

In [55]:
```
#Neste caso como há muitos casos de ESTADO CIVIL diferente de Casado(C) e Solteiro(
#para todos casos que não forem Casado e Solteiro, serão considerado como OUTROS. D
#e os dados ficarão balanceados sem discrepancias.
```

```
sns.countplot(data = df_dados, x = "Estado_Civil", hue = "Possivel_Fraude")
plt.show()
```

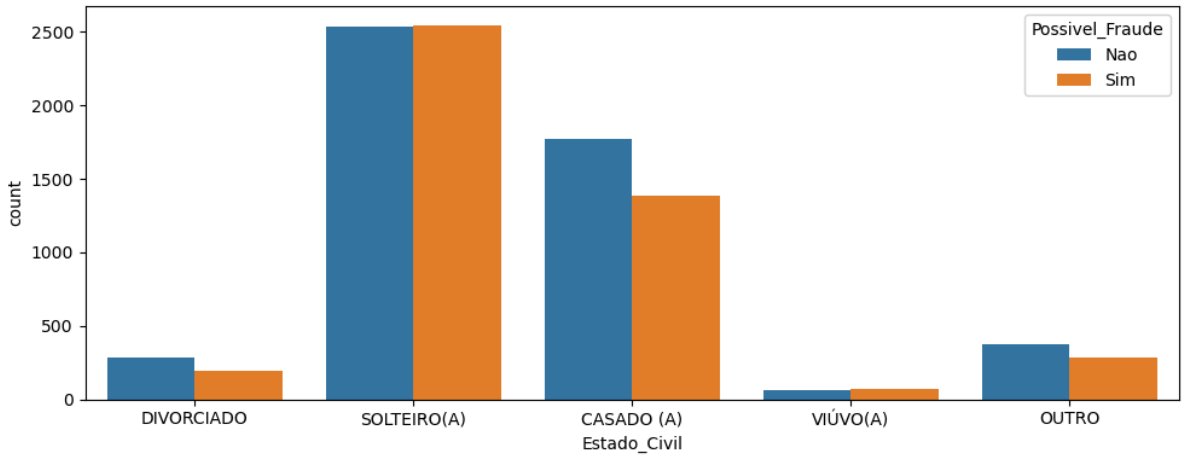

In [56]:
```
#Podemos observar o volume de cotas que geraram prejuízo na arrecadação de taxa de
#Essa variável iremos manter no modelo e avaliar mais adiante
sns.countplot(data = df_dados, x = "Faixa_Dias_Atraso", hue = "Possivel_Fraude")
plt.show()
```

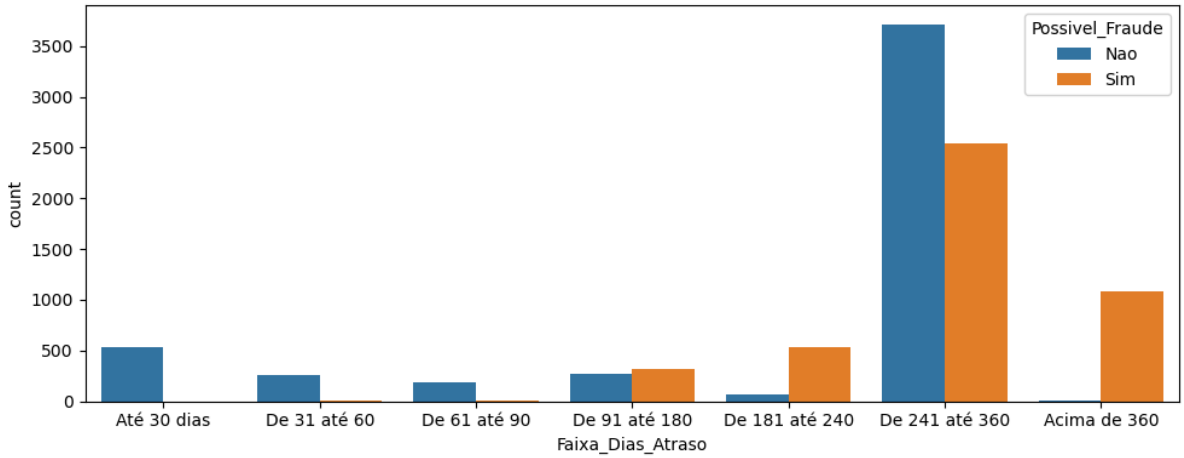

In [57]:
```
# Aqui podemos observar que não há discrepancias nestas variaveis.
sns.countplot(data = df_dados, x = "Faixa_Prazo_Emprestimo", hue = "Possivel_Fraude
plt.show()
```

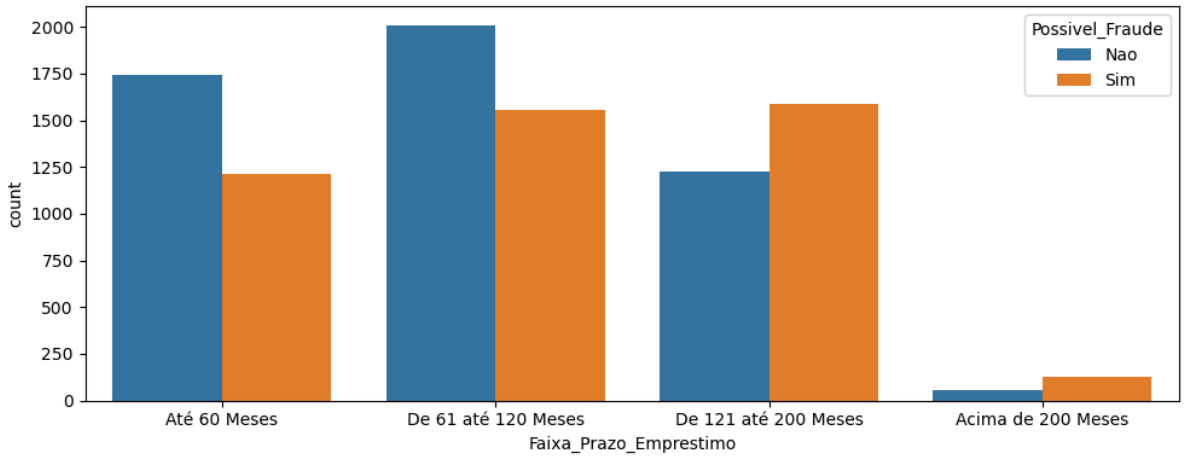

In [58]:
```
# Podemos observar que esta variável está muito desbalanceada, mas iremos avaliar m
sns.countplot(data = df_dados, x = "Faixa_Prazo_Restante", hue = "Possivel_Fraude")
plt.show()
```

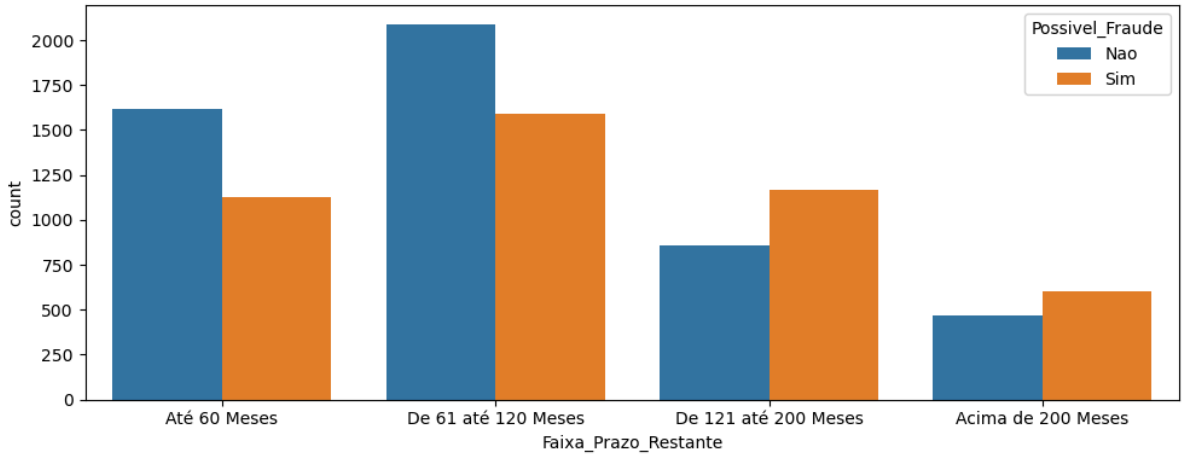

In [59]:
```
df_dados.describe()
```

Out[59]:

	Perc_Juros	VL_Emprestimo	VL_Emprestimo_ComJuros	QT_Total_Parcelas_Pagas	QT_Total_Pa
count	9517.00	9517.00	9517.00	9517.00	
mean	19.65	81881.89	94164.17	7.89	
std	3.82	94138.06	108258.77	5.17	
min	7.00	3500.00	4025.00	0.00	
25%	18.00	20000.00	23000.00	2.00	
50%	20.00	50000.00	57500.00	9.00	
75%	22.00	100000.00	115000.00	13.00	
max	28.00	500000.00	575000.00	35.00	

In [61]:
```
# Total de valores únicos de cada variável do novo dataset
valores_unicos = []
for i in df_dados.columns[0:19].tolist():
    print(i, ':', len(df_dados[i].astype(str).value_counts()))
    valores_unicos.append(len(df_dados[i].astype(str).value_counts()))
```

```
Sexo : 2
UF_Cliente : 27
Perc_Juros : 21
VL_Emprestimo : 61
VL_Emprestimo_ComJuros : 61
QT_Total_Parcelas_Pagas : 24
QT_Total_Parcelas_Pagas_EmDia : 24
QT_Total_Parcelas_Pagas_EmAtraso : 15
Qt_Renegociacao : 10
Estado_Civil : 5
QT_Parcelas_Atraso : 16
Saldo_Devedor : 7654
Total_Pago : 7022
Faixa_Prazo_Restante : 4
Faixa_Salarial : 8
Faixa_Prazo_Emprestimo : 4
Faixa_Etaria : 6
Faixa_Dias_Atraso : 7
Possivel_Fraude : 2
```

Analise Exploratória - Variáveis Numéricas

Nesta analise temos diversos objetivos:

1 - Conhecer as variáveis.

2 - Realizar uma analise estatistica nas variáveis para futuros tratamentos. Iremos avaliar média, mediana, moda, desvio padrão correlações, outliers, distribuição dos dados, etc.

In [62]:
```
#carregar variaveis para plot
variaveis_numericas = []
for i in df_dados.columns[0:19].tolist():
        if df_dados.dtypes[i] == 'int64' or df_dados.dtypes[i] == 'float64':
            variaveis_numericas.append(i)
```

In [63]:
```
#Visualizando as variáveis numéricas
variaveis_numericas
```

Out[63]:
```
['Perc_Juros',
 'VL_Emprestimo',
 'VL_Emprestimo_ComJuros',
 'QT_Total_Parcelas_Pagas',
 'QT_Total_Parcelas_Pagas_EmDia',
 'QT_Total_Parcelas_Pagas_EmAtraso',
 'Qt_Renegociacao',
 'QT_Parcelas_Atraso',
 'Saldo_Devedor',
 'Total_Pago']
```

In [64]:
```
#Quantidade de variaveis
len(variaveis_numericas)
```

Out[64]:
```
10
```

In [65]:
```
#Podemos observar nos boxplots abaixo que as variáveis númericas apresentam uma gra
#Precisamos avaliar cada uma dessas variaveis dentro do contexto dos dados para sab

plt.rcParams["figure.figsize"] = [14.00, 64.00]
plt.rcParams["figure.autolayout"] = True
f, axes = plt.subplots(5, 2) #5 linhas e 2 colunas

linha = 0
coluna = 0
for i in variaveis_numericas:
    sns.boxplot(data = df_dados, y=i, ax=axes[linha][coluna])
    coluna += 1
    if coluna == 2:
        linha += 1
        coluna = 0

plt.show()
```

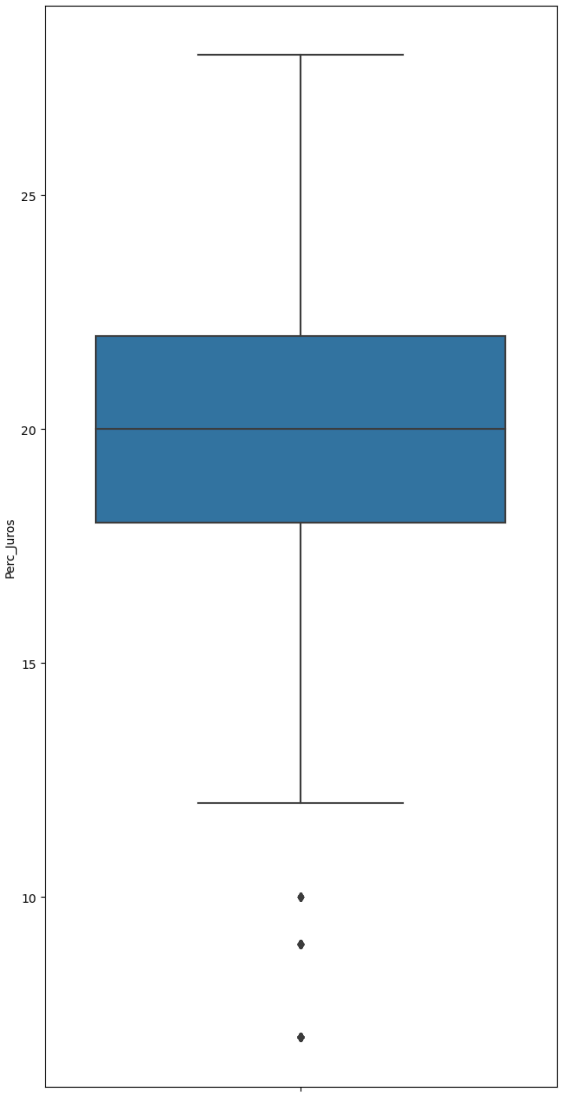
Perc_Juros
25
20
15
10

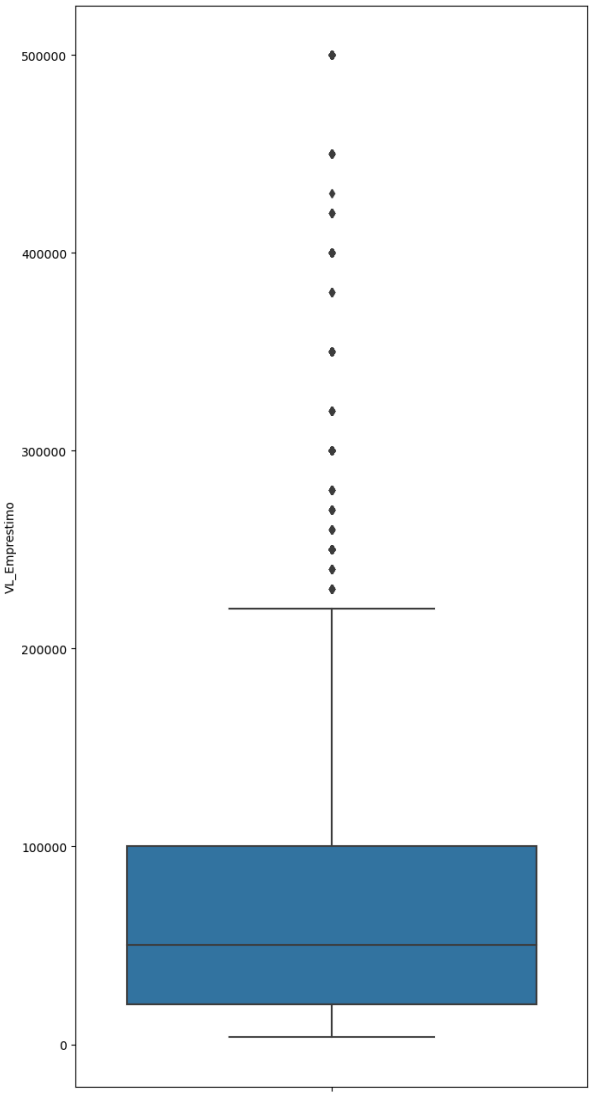
VL_Emprestimo
500000
400000
300000
200000
100000
0

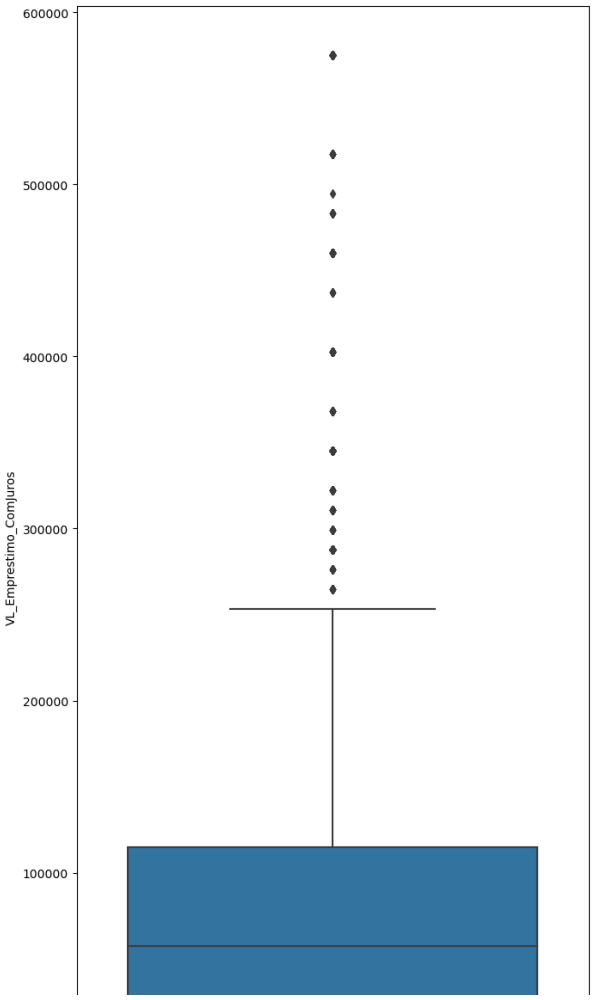
VL_Emprestimo_ComJuros
600000
500000
400000
300000
200000
100000

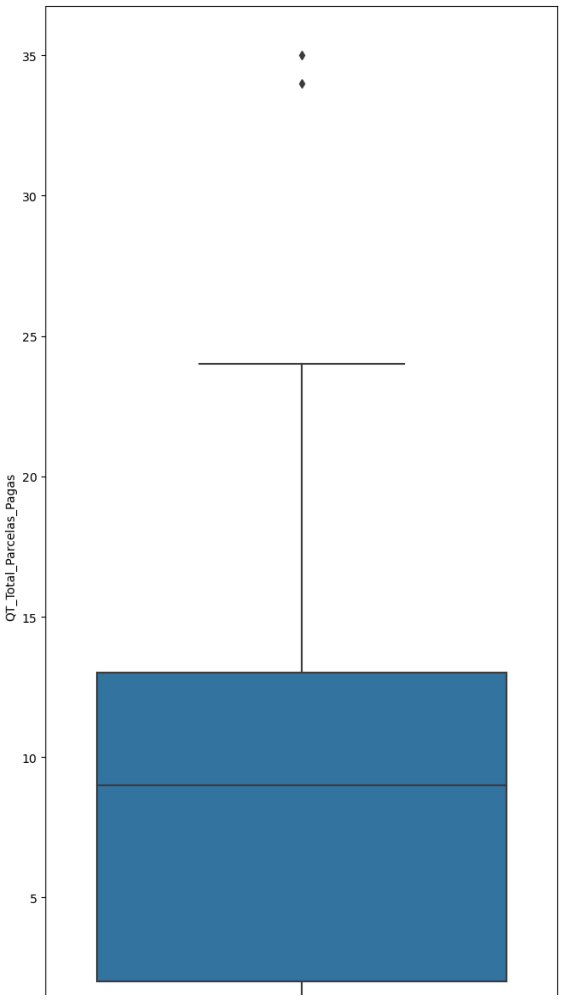
QT_Total_Parcelas_Pagas
35
30
25
20
15
10
5

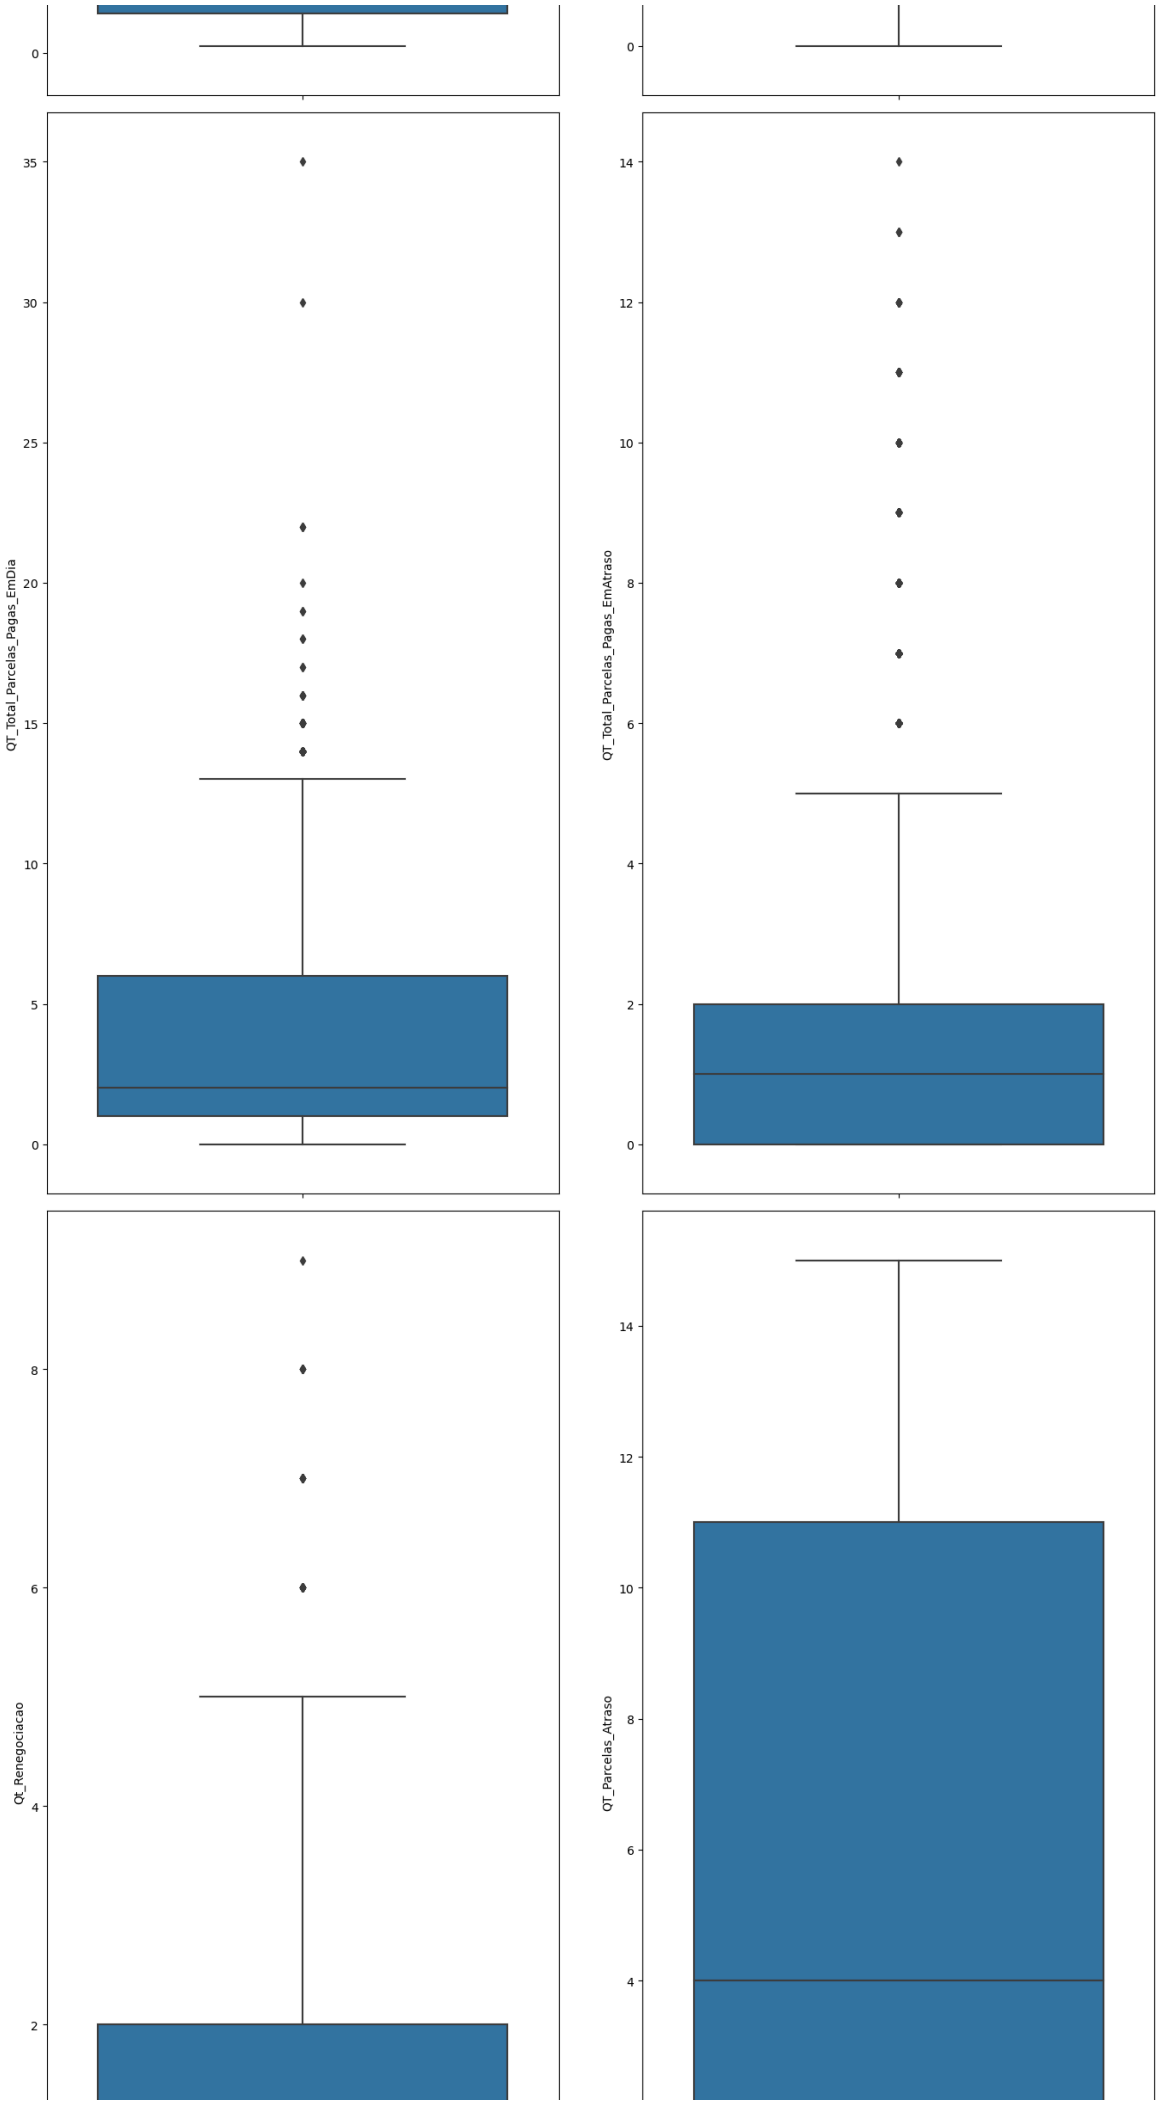
0
0
35
30
25
20
15
10
5
0
QT_Total_Parcelas_Pagas_EmDia
14
12
10
8
6
4
2
0
QT_Total_Parcelas_Pagas_EmAtraso
8
6
4
2
Qt_Renegociacao
14
12
10
8
6
4
QT_Parcelas_Atraso

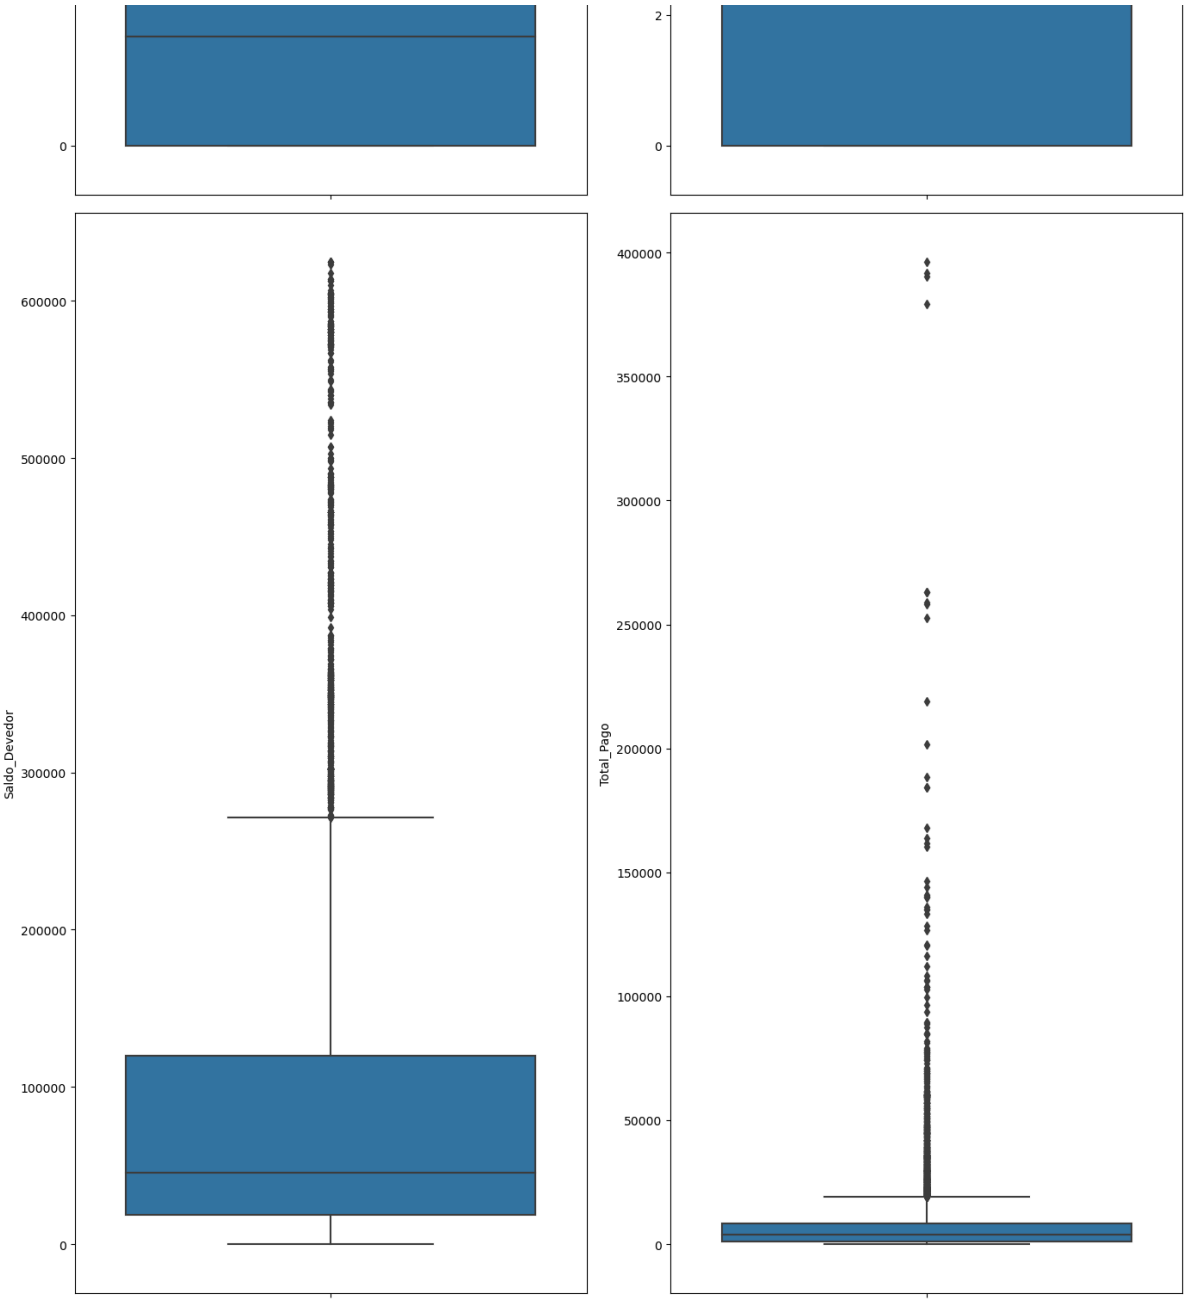

In [66]:
```
# carregar variaveis categoricas para OneHotEncoding
# Vamos colocar o slice somente até a coluna de indice 18 para não pegar a variável
variaveis_categoricas = []
for i in df_dados.columns[0:18].tolist():
        if df_dados.dtypes[i] == 'object' or df_dados.dtypes[i] == 'category':
            variaveis_categoricas.append(i)
```

In [67]:
```
# Visualizando as variaveis categoricas
variaveis_categoricas
```

Out[67]:
```
['Sexo',
 'UF_Cliente',
 'Estado_Civil',
 'Faixa_Prazo_Restante',
 'Faixa_Salarial',
 'Faixa_Prazo_Emprestimo',
 'Faixa_Etaria',
 'Faixa_Dias_Atraso']
```

In [68]:
```
df_dados.head()
```

Out[68]:

	Sexo	UF_Cliente	Perc_Juros	VL_Emprestimo	VL_Emprestimo_ComJuros	QT_Total_Parcelas_Paga
0	M	SP	23.00	80000.00	92000.00	1
1	M	MG	20.00	50000.00	57500.00	1
2	M	BA	18.00	100000.00	115000.00	1
3	M	MG	20.00	30000.00	34500.00	
4	M	MG	20.00	60000.00	69000.00	1

In [69]:
```
# Cria o encoder e aplica OneHotEncoder
lb = LabelEncoder()

for var in variaveis_categoricas:
    df_dados[var] = lb.fit_transform(df_dados[var])
```

In [70]:
```
# Verifica novamente para confirmar se após transformação surgiu algum valor nulo
df_dados.isnull().sum()
```

Out[70]:
```
Sexo                          0
UF_Cliente                    0
Perc_Juros                    0
VL_Emprestimo                 0
VL_Emprestimo_ComJuros        0
QT_Total_Parcelas_Pagas       0
QT_Total_Parcelas_Pagas_EmDia 0
QT_Total_Parcelas_Pagas_EmAtraso 0
Qt_Renegociacao               0
Estado_Civil                  0
QT_Parcelas_Atraso            0
Saldo_Devedor                 0
Total_Pago                    0
Faixa_Prazo_Restante          0
Faixa_Salarial                0
Faixa_Prazo_Emprestimo        0
Faixa_Etaria                  0
Faixa_Dias_Atraso             0
Possivel_Fraude               0
dtype: int64
```

In [71]:
```
df_dados.head()
```

Out[71]:

	Sexo	UF_Cliente	Perc_Juros	VL_Emprestimo	VL_Emprestimo_ComJuros	QT_Total_Parcelas_Paga
0	1	25	23.00	80000.00	92000.00	1
1	1	10	20.00	50000.00	57500.00	1
2	1	4	18.00	100000.00	115000.00	1
3	1	10	20.00	30000.00	34500.00	
4	1	10	20.00	60000.00	69000.00	1

In [72]:
```
# Visualizando os tipos das variaveis
df_dados.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9517 entries, 0 to 9516
Data columns (total 19 columns):
 #   Column                          Non-Null Count  Dtype  
---  ------                          --------------  -----  
 0   Sexo                            9517 non-null   int32  
 1   UF_Cliente                      9517 non-null   int32  
 2   Perc_Juros                      9517 non-null   float64
 3   VL_Emprestimo                   9517 non-null   float64
 4   VL_Emprestimo_ComJuros          9517 non-null   float64
 5   QT_Total_Parcelas_Pagas         9517 non-null   int64  
 6   QT_Total_Parcelas_Pagas_EmDia   9517 non-null   int64  
 7   QT_Total_Parcelas_Pagas_EmAtraso  9517 non-null   int64  
 8   Qt_Renegociacao                 9517 non-null   int64  
 9   Estado_Civil                    9517 non-null   int32  
 10  QT_Parcelas_Atraso              9517 non-null   int64  
 11  Saldo_Devedor                   9517 non-null   float64
 12  Total_Pago                      9517 non-null   float64
 13  Faixa_Prazo_Restante            9517 non-null   int32  
 14  Faixa_Salarial                  9517 non-null   int32  
 15  Faixa_Prazo_Emprestimo          9517 non-null   int32  
 16  Faixa_Etaria                    9517 non-null   int32  
 17  Faixa_Dias_Atraso               9517 non-null   int32  
 18  Possivel_Fraude                 9517 non-null   object 
dtypes: float64(5), int32(8), int64(5), object(1)
memory usage: 1.1+ MB
```

In [73]:
```
# Visualiznado a quantidade da variavel target para balanceamento
variavel_target = df_dados.Possivel_Fraude.value_counts()
variavel_target
```

Out[73]:
```
Nao    5035
Sim    4482
Name: Possivel_Fraude, dtype: int64
```

In [74]:
```
#Separar variaveis preditoras e target
PREDITORAS = df_dados.iloc[:, 0:18]
TARGET = df_dados.iloc[:, 18]
```

In [75]:
```
# Visualizando as variaveis preditoras
PREDITORAS.head()
```

Out[75]:

	Sexo	UF_Cliente	Perc_Juros	VL_Emprestimo	VL_Emprestimo_ComJuros	QT_Total_Parcelas_Paga
0	1	25	23.00	80000.00	92000.00	1
1	1	10	20.00	50000.00	57500.00	1
2	1	4	18.00	100000.00	115000.00	1
3	1	10	20.00	30000.00	34500.00	
4	1	10	20.00	60000.00	69000.00	1

In [76]:
```
# Visualizando a variavel target
TARGET.head()
```

Out[76]:
```
0    Nao
1    Nao
2    Nao
3    Sim
4    Nao
Name: Possivel_Fraude, dtype: object
```

In [77]:
```
# Seed para reproduzir o mesmo resultado
seed = 100

# Cria o balanceador SMOTE
balanceador = SMOTE(random_state = seed)

# Aplica o balanceador
PREDITORAS_RES, TARGET_RES = balanceador.fit_resample(PREDITORAS, TARGET)
```

In [78]:
```
# Visualizando o balanceamento da variável TARGET
plt.rcParams["figure.figsize"] = [12.00, 5.00]
plt.rcParams["figure.autolayout"] = True
TARGET_RES.value_counts().plot(kind='bar', title='Possíveis Fraudes x Não Fraudes',
```

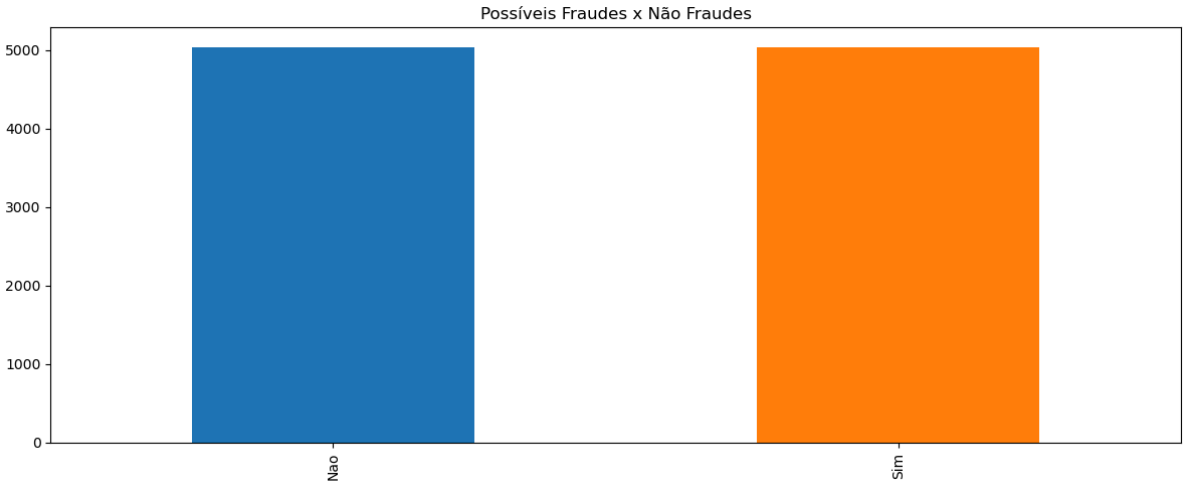

In [79]:
```
# Quantidade de registros antes do balanceamento
PREDITORAS.shape
```

Out[79]:
```
(9517, 18)
```

In [80]:
```
# Quantidade de registros antes do balanceamento
TARGET.shape
```

Out[80]:
```
(9517,)
```

In [81]:
```
# Quantidade de registros após do balanceamento
PREDITORAS_RES.shape
```

Out[81]:
```
(10070, 18)
```

In [82]:
```
# Quantidade de registros após do balanceamento
TARGET_RES.shape
```

Out[82]:
```
(10070,)
```

In [ ]:
```

```

In [ ]:
```
## Agora vamos dividir os dados em dados de treino e teste para iniciarmos a etapa
```

In [83]:
```
# Divisão em Dados de Treino e Teste.
X_treino, X_teste, Y_treino, Y_teste = train_test_split(PREDITORAS_RES, TARGET_RES,
```

In [84]:
```
X_treino.shape
```

Out[84]:
```
(7049, 18)
```

In [85]:
```
X_treino.head()
```

Out[85]:

	Sexo	UF_Cliente	Perc_Juros	VL_Emprestimo	VL_Emprestimo_ComJuros	QT_Total_Parcelas_P
7012	0	17	19.00	500000.00	575000.00	
8541	0	25	20.00	140000.00	161000.00	
3903	0	4	28.00	12000.00	13800.00	
1844	0	25	18.00	50000.00	57500.00	
8303	1	9	21.00	15000.00	17250.00	

In [86]:
```
# Normalização das Variáveis
Normalizador = MinMaxScaler()
X_treino_normalizados = Normalizador.fit_transform(X_treino)
X_teste_normalizados = Normalizador.transform(X_teste)
```

In [87]:
```
X_treino_normalizados.shape
```

Out[87]:
```
(7049, 18)
```

In [89]:
```
# Visualizando os dados NORMALIZADOS
X_treino_normalizados
```

Out[89]:
```
array([[0.        , 0.65384615, 0.57142857, ..., 0.66666667, 1.        ,
        0.5       ],
       [0.        , 0.96153846, 0.61904762, ..., 0.66666667, 1.        ,
        0.33333333],
       [0.        , 0.15384615, 1.        , ..., 0.33333333, 0.4       ,
        0.        ],
       ...,
       [1.        , 0.96153846, 0.71428571, ..., 0.66666667, 0.4       ,
        0.5       ],
       [1.        , 0.88461538, 0.57142857, ..., 0.66666667, 0.8       ,
        1.        ],
       [1.        , 0.96153846, 0.85714286, ..., 1.        , 0.8       ,
        0.5       ]])
```

In [ ]:
```

```

In [90]:
```
# Padronizacao das Variáveis
Padronizador = StandardScaler()
X_treino_padronizados = Padronizador.fit_transform(X_treino)
X_teste_padronizados = Padronizador.transform(X_teste)
```

In [91]:
```
# Visualizando os dados PADRONIZADOS
X_treino_padronizados
```

Out[91]:
```
array([[-1.19681542,  0.23366629, -0.17570736, ..., -0.0233426 ,
         1.62615057,  0.21145893],
       [-1.19681542,  1.30019073,  0.08623913, ..., -0.0233426 ,
         1.62615057, -0.50688999],
       [-1.19681542, -1.49943592,  2.18181105, ..., -1.17398585,
        -0.69596477, -1.94358782],
       ...,
       [ 0.83555073,  1.30019073,  0.61013211, ..., -0.0233426 ,
        -0.69596477,  0.21145893],
       [ 0.83555073,  1.03355962, -0.17570736, ..., -0.0233426 ,
         0.85211213,  2.36650569],
       [ 0.83555073,  1.30019073,  1.39597158, ...,  1.12730065,
         0.85211213,  0.21145893]])
```

Criando, Treinando e Avaliando os Modelos de Machine Learning

Primeiro iremos fazer com o Random Forest

In [92]:
```
# Construtor do Modelo
randomForest = RandomForestClassifier()
```

In [93]:
```
# Parametros default
randomForest.get_params()
```

Out[93]:
```
{'bootstrap': True,
 'ccp_alpha': 0.0,
 'class_weight': None,
 'criterion': 'gini',
 'max_depth': None,
 'max_features': 'sqrt',
 'max_leaf_nodes': None,
 'max_samples': None,
 'min_impurity_decrease': 0.0,
 'min_samples_leaf': 1,
 'min_samples_split': 2,
 'min_weight_fraction_leaf': 0.0,
 'n_estimators': 100,
 'n_jobs': None,
 'oob_score': False,
 'random_state': None,
 'verbose': 0,
 'warm_start': False}
```

In [94]:
```
# Valores para o grid de hiperparametros
n_estimators = np.array([100,200,300])
max_depth = np.array([10,20])
criterion = np.array(["gini", "entropy"])
max_features = np.array(["sqrt", "log2", None])
min_samples_split = np.array([1,2,5])
min_samples_leaf = np.array([1,2,3])


# Grid de hiperparâmetros
grid_parametros = dict(n_estimators = n_estimators,
                       max_depth = max_depth,
                       criterion = criterion,
                       max_features = max_features,
                       min_samples_split = min_samples_split,
```

```
                        min_samples_leaf = min_samples_leaf)

# Criando o modelo com o Grid de Hiperparametros
randomForest = GridSearchCV(randomForest, grid_parametros, cv = 3, n_jobs = 8)

# Treinando os modelos
inicio = time.time()
randomForest.fit(X_treino_normalizados, Y_treino)
fim = time.time()

# Obtendo e visualizando os parametros treinados
treinos_rf = pd.DataFrame(randomForest.cv_results_)

# Acurácia em Treino
print(f"Acurácia em Treinamento: {randomForest.best_score_ :.2%}")
print("")
print(f"Hiperparâmetros Ideais: {randomForest.best_params_}")
print("")
print("Tempo de Treinamento do Modelo: ", round(fim - inicio,2))
print("")
print("Numero de treinamentos realizados: ", treinos_rf.shape[0])
```

```
Acurácia em Treinamento: 99.26%

Hiperparâmetros Ideais: {'criterion': 'entropy', 'max_depth': 20, 'max_features':
'log2', 'min_samples_leaf': 1, 'min_samples_split': 1, 'n_estimators': 100}

Tempo de Treinamento do Modelo:  314.33

Numero de treinamentos realizados:  324
```

In [95]:
```
# Criando o classificador com Random Forest
clf = RandomForestClassifier(n_estimators  = 100, criterion = 'entropy', max_depth
                             max_features = 'log2', min_samples_leaf = 1, min_sampl

# Construção do modelo
clf = clf.fit(X_treino_normalizados, Y_treino)
```

In [96]:
```
# Exibindo a importancia de cada variavel no modelo preditivo
plt.rcParams["figure.figsize"] = [10.00, 16.00]
plt.rcParams["figure.autolayout"] = True

importances = pd.Series(data=clf.feature_importances_, index=PREDITORAS.columns)
importances = importances.sort_values(ascending = False)
sns.barplot(x=importances, y=importances.index, orient='h').set_title('Importância
plt.show()
```

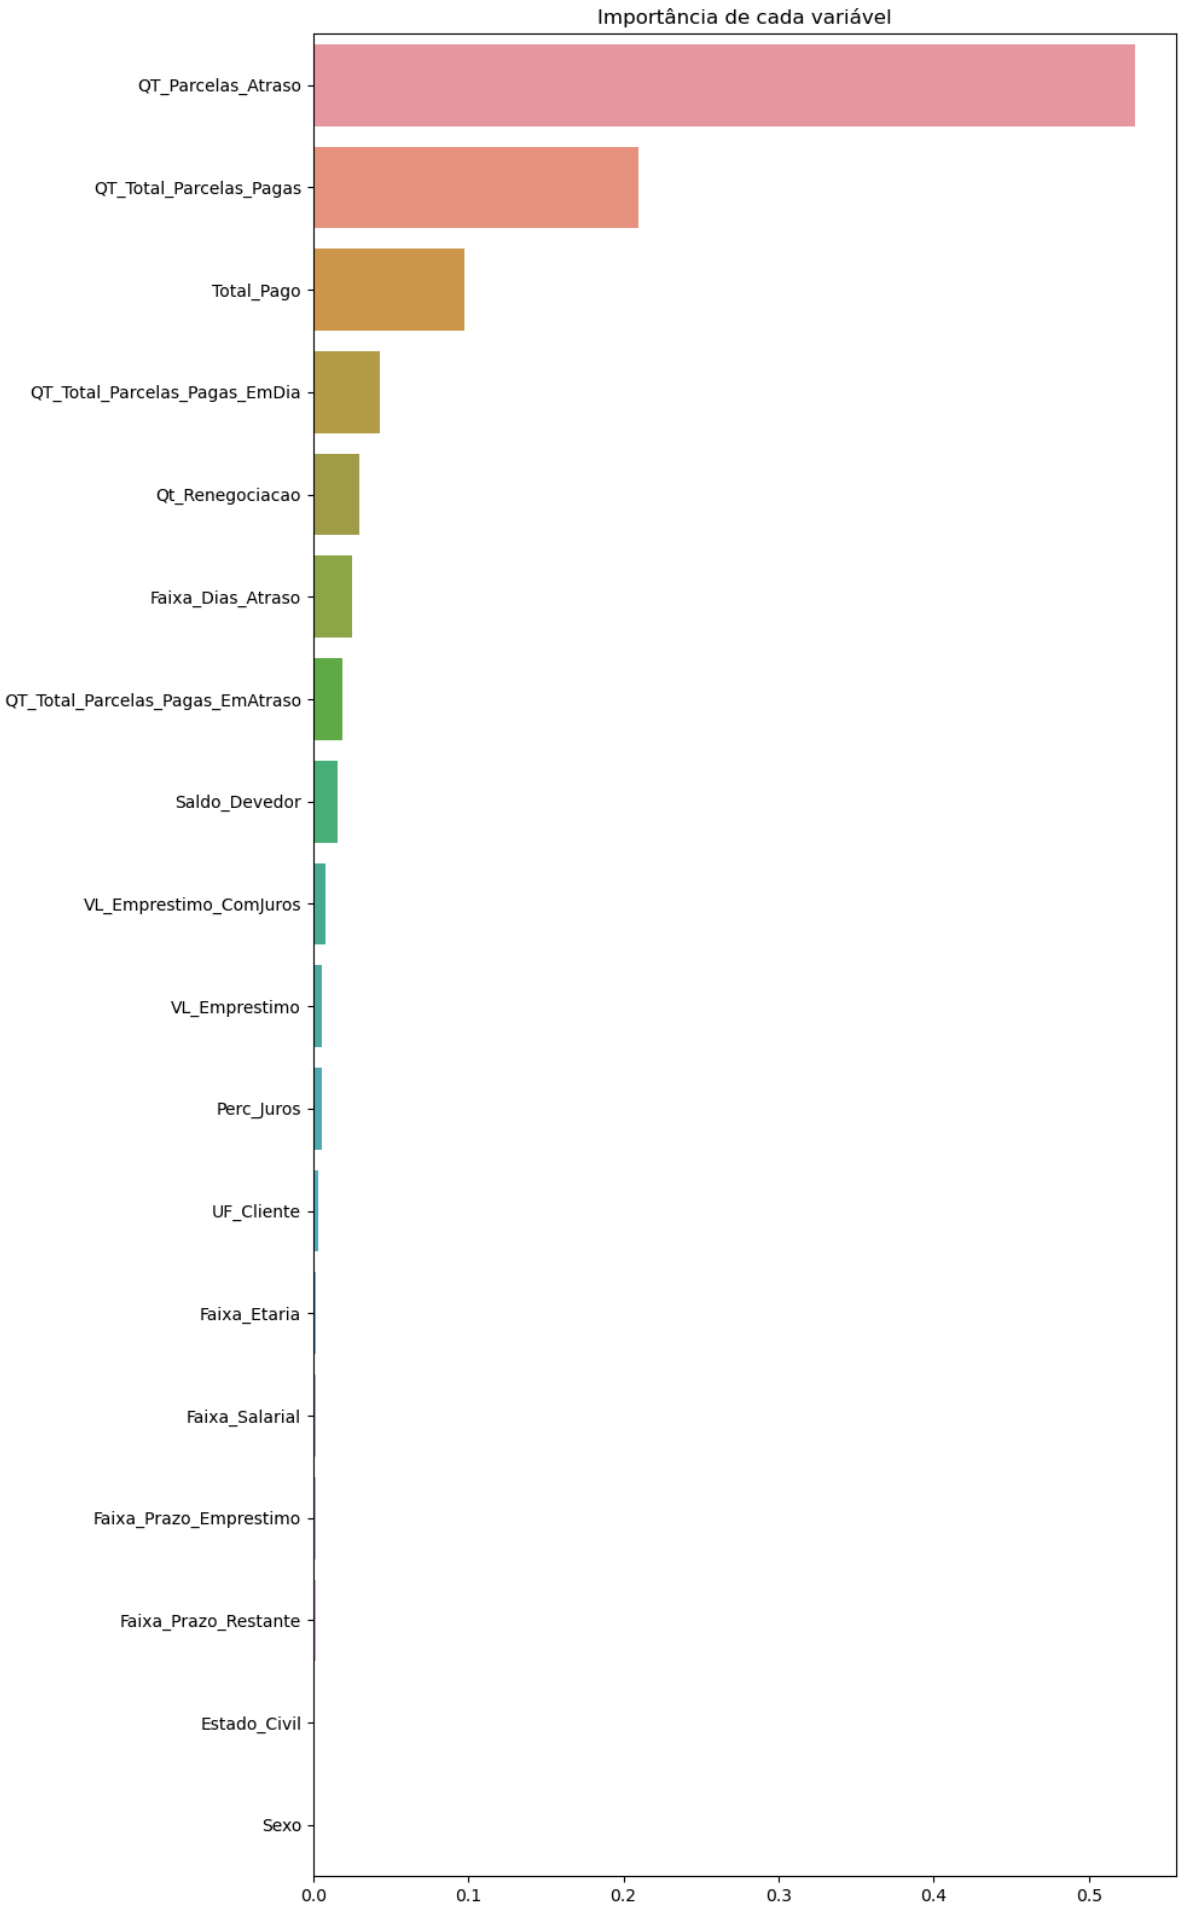

In [97]:
```
# Visualizando o percentual de importancia de cada variável
importances.sort_values(ascending = False)
```

Out[97]:
```
QT_Parcelas_Atraso                0.53
QT_Total_Parcelas_Pagas           0.21
Total_Pago                        0.10
QT_Total_Parcelas_Pagas_EmDia     0.04
Qt_Renegociacao                   0.03
Faixa_Dias_Atraso                 0.03
QT_Total_Parcelas_Pagas_EmAtraso  0.02
Saldo_Devedor                     0.02
VL_Emprestimo_ComJuros            0.01
VL_Emprestimo                     0.01
Perc_Juros                        0.01
UF_Cliente                        0.00
Faixa_Etaria                      0.00
Faixa_Salarial                    0.00
Faixa_Prazo_Emprestimo            0.00
Faixa_Prazo_Restante              0.00
Estado_Civil                      0.00
Sexo                              0.00
dtype: float64
```

In [98]:
```
# Estamos apenas "simulando" os dados de teste
scores = clf.score(X_treino_normalizados,Y_treino)
scores
```

Out[98]:
```
1.0
```

In [99]:
```
# Estamos apenas "simulando" os dados de teste
scores = clf.score(X_teste_normalizados,Y_teste)
scores
```

Out[99]:
```
0.9897384971863621
```

In [100…
```
# Dicionário de métricas e metadados
modelo_rf = {'Melhores Hiperparametros':randomForest.best_params_,
             'Numero de Modelos Treinados': treinos_rf.shape[0],
             'Melhor Score': str(round(randomForest.best_score_ * 100,2))+"%"}
```

In [101…
```
modelo_rf
```

Out[101]:
```
{'Melhores Hiperparametros': {'criterion': 'entropy',
  'max_depth': 20,
  'max_features': 'log2',
  'min_samples_leaf': 1,
  'min_samples_split': 1,
  'n_estimators': 100},
 'Numero de Modelos Treinados': 324,
 'Melhor Score': '99.26%'}
```

In [102…
```
# Construtor do modelo
modelo_svm = SVC()
```

In [103…
```
# Parametros default
modelo_svm.get_params()
```

Out[103]:
```
{'C': 1.0,
 'break_ties': False,
 'cache_size': 200,
 'class_weight': None,
 'coef0': 0.0,
 'decision_function_shape': 'ovr',
 'degree': 3,
 'gamma': 'scale',
 'kernel': 'rbf',
 'max_iter': -1,
 'probability': False,
 'random_state': None,
 'shrinking': True,
 'tol': 0.001,
 'verbose': False}
```

In [104…
```
# Valores para o grid de hiperparametros
grid_parametros = {'C': [0.1,1,10,100],
                   'gamma': [1,0.1,0.01,0.001],
                   #'kernel': ['poly','rbf','sigmoid','linear'],
                   'degree' : [2,3,4,],
                   'coef0' : [0.5,1],
                   #'decision_function_shape':['ovo', 'ovr'],
                   'max_iter': [-1, 1]}


svm = GridSearchCV(modelo_svm, grid_parametros, n_jobs = 8)

# Treinando os modelos
inicio = time.time()
svm.fit(X_treino_normalizados, Y_treino)
fim = time.time()

# Obtendo e visualizando os parametros treinados
treinos_svm = pd.DataFrame(svm.cv_results_)

# Acurácia em Treino
print(f"Acurácia em Treinamento: {svm.best_score_ :.2%}")
print("")
print(f"Hiperparâmetros Ideais: {svm.best_params_}")
print("")
print("Tempo de Treinamento do Modelo: ", round(fim - inicio,2))
print("")
print("Numero de treinamentos realizados: ", treinos_svm.shape[0])
```

```
Acurácia em Treinamento: 98.92%

Hiperparâmetros Ideais: {'C': 100, 'coef0': 0.5, 'degree': 2, 'gamma': 0.01, 'max_
iter': -1}

Tempo de Treinamento do Modelo:  95.71

Numero de treinamentos realizados:  192
```

In [105…
```
# Dicionário de métricas e metadados
modelo_svm = {'Melhores Hiperparametros':svm.best_params_,
              'Numero de Modelos Treinados': treinos_svm.shape[0],
              'Melhor Score': str(round(svm.best_score_ * 100,2))+"%"}
```

In [ ]:

In [ ]:

In [110…
```
# Classificador
knn = KNeighborsClassifier()
```

In [111…
```
# Parametros default
knn.get_params()
```

Out[111]:
```
{'algorithm': 'auto',
 'leaf_size': 30,
 'metric': 'minkowski',
 'metric_params': None,
 'n_jobs': None,
 'n_neighbors': 5,
 'p': 2,
 'weights': 'uniform'}
```

In [112…
```
# Valores para o grid de hiperparametros
n_neighbors = np.array([3,4,5,6,7])
algorithm = np.array(['auto', 'ball_tree', 'kd_tree', 'brute'])
leaf_size = np.array([30,31,32])
metric =  np.array(['minkowski','euclidean'])


# Grid de hiperparâmetros
grid_parametros = dict(n_neighbors = n_neighbors,
                       algorithm = algorithm,
                       leaf_size = leaf_size,
                       metric = metric)

knn = GridSearchCV(knn, grid_parametros, n_jobs = 8)

# Treinando os modelos
inicio = time.time()
knn.fit(X_treino_normalizados, Y_treino)
fim = time.time()

# Obtendo e visualizando os parametros treinados
treinos_knn = pd.DataFrame(knn.cv_results_)

# Acurácia em Treino
print(f"Acurácia em Treinamento: {knn.best_score_ :.2%}")
print("")
print(f"Hiperparâmetros Ideais: {knn.best_params_}")
print("")
print("Tempo de Treinamento do Modelo: ", round(fim - inicio,2))
print("")
print("Numero de treinamentos realizados: ", treinos_knn.shape[0])
```

```
Acurácia em Treinamento: 97.04%

Hiperparâmetros Ideais: {'algorithm': 'auto', 'leaf_size': 30, 'metric': 'minkowsk
i', 'n_neighbors': 5}

Tempo de Treinamento do Modelo:  26.33

Numero de treinamentos realizados:  120
```

In [113…
```
# Dicionário de métricas e metadados
modelo_knn = {'Melhores Hiperparametros':knn.best_params_,
              'Numero de Modelos Treinados': treinos_knn.shape[0],
              'Melhor Score': str(round(knn.best_score_ * 100,2))+"%"}
```

In [ ]:

In [114…
```
# Gerando o DataFrame com todos os valores de todos os modelos treinados
resumo = pd.DataFrame({'Random Forest':pd.Series(modelo_rf),
                       'SVM':pd.Series(modelo_svm),
                       'KNN':pd.Series(modelo_knn)})
```

In [115…
```
resumo
```

Out[115]:

	Random Forest	SVM	KNN
Melhores Hiperparametros	{'criterion': 'entropy', 'max_depth': 20, 'max...	{'C': 100, 'coef0': 0.5, 'degree': 2, 'gamma':...	{'algorithm': 'auto', 'leaf_size': 30, 'metric...
Numero de Modelos Treinados	324	192	120
Melhor Score	99.26%	98.92%	97.04%

In [ ]: